

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM  
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG  
KHOA CÔNG NGHỆ THÔNG TIN**



**NGUYỄN VĂN TUẤN - 52200204  
CAO MINH QUÂN - 52200136**

# **DỰ ĐOÁN THỜI GIAN HOẠT ĐỘNG CÒN LẠI CỦA MỘT HỆ THỐNG**

## **BÁO CÁO CUỐI KỲ DỰ ÁN CÔNG NGHỆ THÔNG TIN**

**THÀNH PHỐ HỒ CHÍ MINH, NĂM 2025**

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM**  
**TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG**  
**KHOA CÔNG NGHỆ THÔNG TIN**



**NGUYỄN VĂN TUẤN - 52200204**  
**CAO MINH QUÂN - 52200136**

# **DỰ ĐOÁN THỜI GIAN HOẠT ĐỘNG CÒN LẠI CỦA MỘT HỆ THỐNG**

## **BÁO CÁO CUỐI KỲ** **DỰ ÁN CÔNG NGHỆ THÔNG TIN**

Người hướng dẫn  
**TS. Trịnh Hùng Cường**

**THÀNH PHỐ HỒ CHÍ MINH, NĂM 2025**

## LỜI CẢM ƠN

Nhóm xin chân thành cảm ơn tới **Thầy Trịnh Hùng Cường**, giảng viên Khoa Công Nghệ Thông Tin Trường Đại học Tôn Đức Thắng, vì đã luôn đồng hành, hỗ trợ và hướng dẫn trong suốt quá trình học tập và thực hiện môn Dự án Công nghệ Thông tin. Những định hướng chính xác, sự tận tâm cùng các góp ý khoa học của Thầy đã giúp nhóm nâng cao kiến thức chuyên môn, rèn luyện kỹ năng nghiên cứu và hoàn thiện đề tài một cách hiệu quả nhất. Bên cạnh đó, nhóm cũng xin gửi lời tri ân đến Quý Thầy, Cô của Khoa Công nghệ Thông tin vì đã tạo điều kiện thuận lợi, hỗ trợ trong suốt thời gian học tập và hoàn thành dự án. Cuối cùng, xin chân thành cảm ơn gia đình và bạn bè, những người đã luôn ở bên động viên, khích lệ và tiếp thêm tinh thần để nhóm có thể hoàn thành báo cáo này một cách tốt đẹp.

*TP. Hồ Chí Minh, ngày 28 tháng 12 năm 2025*

*Tác giả*

*(Ký tên và ghi rõ họ tên)*

*Tuấn*

*Nguyễn Văn Tuấn*

*Quân*

*Cao Minh Quân*

## **DỰ ÁN ĐƯỢC HOÀN THÀNH**

### **TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG**

Nhóm xin cam đoan đây là dự án nghiên cứu của nhóm và được sự hướng dẫn khoa học của TS. Trịnh Hùng Cường. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

**Nếu phát hiện có bất kỳ sự gian lận nào nhóm xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình.** Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

*TP. Hồ Chí Minh, ngày 28 tháng 12 năm 2025*

*Tác giả*

*(Ký tên và ghi rõ họ tên)*

*Tuấn*

*Nguyễn Văn Tuấn*

*Quân*

*Cao Minh Quân*

# **DỰ ĐOÁN THỜI GIAN HOẠT ĐỘNG CÒN LẠI CỦA MỘT HỆ THỐNG**

## **TÓM TẮT**

Đề tài “Dự đoán thời gian hoạt động còn lại của một hệ thống” cụ thể là pin Li-on tập trung vào việc nghiên cứu và xây dựng mô hình dự đoán RUL dựa trên dữ liệu đo đạc thực nghiệm được công bố, bao gồm các thông số vận hành quan trọng của pin như chu kỳ sử dụng, thời gian sạc – xả, điện áp cực đại và cực tiểu, cũng như các đặc trưng phản ánh quá trình suy giảm hiệu suất. Việc ước lượng chính xác RUL giúp các hệ thống dự đoán hỏng hóc sớm đưa ra chiến lược bảo trì hiệu quả, đồng thời nâng cao độ tin cậy cho các thiết bị sử dụng pin.

Trên cơ sở dữ liệu đã xử lý, đề tài triển khai song song hai hướng tiếp cận: học máy truyền thống (Machine Learning) và học sâu (Deep Learning). Các mô hình ML như Linear Regression, Random Forest và XGBoost được xây dựng để đánh giá khả năng dự đoán RUL với dữ liệu dạng bảng. Trong khi đó, các mô hình DL gồm LSTM, GRU và CNN được áp dụng nhằm kiểm tra khả năng học theo chuỗi thời gian và trích rút đặc trưng theo trình tự. Kết quả thực nghiệm cho thấy nhóm mô hình ML, đặc biệt là Random Forest và XGBoost, đạt hiệu suất rất cao với sai số thấp và hệ số xác định  $R^2$  gần tuyệt đối, trong khi một số mô hình sâu như GRU và CNN không đạt hiệu quả tốt do dữ liệu thiếu cấu trúc chuỗi thời gian ổn định.

Cuối cùng, các mô hình được so sánh toàn diện dựa trên các thước đo RMSE, MAE và  $R^2$  nhằm xác định mô hình tối ưu. XGBoost và Random Forest chứng minh độ chính xác vượt trội, cho thấy dữ liệu RUL của pin phù hợp hơn với các mô hình cây quyết định tăng cường (boosting) và tổ hợp mô hình (ensemble) so với các mô hình học chuỗi truyền thống. Kết quả của đề tài không chỉ phản ánh tiềm năng của các mô hình học máy trong dự đoán RUL mà còn cung cấp cơ sở để phát triển các hệ thống dự đoán hỏng hóc pin phục vụ thực tế. Ngoài ra, đề tài cũng mở ra hướng mở rộng như cải thiện kiến trúc DL theo dạng time-series thực sự, bổ sung thêm dữ liệu cảm biến và phát triển giao diện ứng dụng minh họa.

## MỤC LỤC

|                                                                  |            |
|------------------------------------------------------------------|------------|
| <b>DANH MỤC HÌNH VẼ .....</b>                                    | <b>vii</b> |
| <b>DANH MỤC BẢNG BIỂU .....</b>                                  | <b>x</b>   |
| <b>DANH MỤC CÁC CHỮ VIẾT TẮT.....</b>                            | <b>xi</b>  |
| <b>CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI.....</b>                 | <b>1</b>   |
| 1.1 Lý do chọn đề tài.....                                       | 1          |
| 1.2 Mục tiêu thực hiện đề tài.....                               | 2          |
| 1.3 Đối tượng và phạm vi nghiên cứu.....                         | 3          |
| 1.4 Ý nghĩa khoa học và thực tiễn của đề tài .....               | 3          |
| <b>CHƯƠNG 2. PHÂN TÍCH DỮ LIỆU VÀ TRỰC QUAN HÓA DỮ LIỆU.....</b> | <b>5</b>   |
| 2.1 Phân tích dữ liệu sử dụng.....                               | 5          |
| 2.1.1 Giới thiệu và mô tả bộ dữ liệu .....                       | 5          |
| 2.1.2 Khám phá dữ liệu ban đầu.....                              | 7          |
| 2.1.3 Phân tích mối quan hệ giữa các đặc trưng.....              | 7          |
| 2.2 Trực quan hóa dữ liệu .....                                  | 8          |
| 2.2.1 Trực quan hóa phân bố của RUL .....                        | 8          |
| 2.2.2 Trực quan hóa xu hướng RUL theo số chu kỳ hoạt động .....  | 9          |
| 2.2.3 Trực quan hóa ma trận tương quan giữa các đặc trưng .....  | 10         |
| <b>CHƯƠNG 3. XỬ LÝ TẬP DỮ LIỆU .....</b>                         | <b>12</b>  |
| 3.1 Kiểm tra và xử lý giá trị thiếu (Missing Values) .....       | 12         |
| 3.2 Xử lý giá trị ngoại lai (Outliers).....                      | 13         |
| 3.3 Kiểm tra và lưu dữ liệu .....                                | 14         |
| <b>CHƯƠNG 4. CÁC MÔ HÌNH ĐƯỢC SỬ DỤNG TRONG BÀI TOÁN .....</b>   | <b>16</b>  |

|                                                                                                         |           |
|---------------------------------------------------------------------------------------------------------|-----------|
| 4.1 Các mô hình học máy (Machine Learning) .....                                                        | 16        |
| 4.1.1 Mô hình <i>Linear Regression</i> .....                                                            | 16        |
| 4.1.2 Mô hình <i>Random Forest</i> .....                                                                | 18        |
| 4.1.3 Mô hình <i>XGBoost</i> .....                                                                      | 21        |
| 4.2 Các mô hình học sâu (Deep Learning).....                                                            | 23        |
| 4.2.1 Mô hình <i>Long Short-Term Memory (LSTM)</i> .....                                                | 23        |
| 4.2.2 Mô hình <i>Gated Recurrent Unit (GRU)</i> .....                                                   | 26        |
| 4.2.3 Mô hình <i>Convolutional Neural Network</i> .....                                                 | 28        |
| <b>CHƯƠNG 5. THỰC NGHIỆM VÀ SO SÁNH KẾT QUẢ.....</b>                                                    | <b>31</b> |
| 5.1 Thực nghiệm .....                                                                                   | 31        |
| 5.1.1 Các thư viện được sử dụng .....                                                                   | 31        |
| 5.1.2 Đọc dữ liệu đã tiền xử lý và <i>Feature engineering</i> .....                                     | 31        |
| 5.1.3 Chia dữ liệu và chuẩn hóa .....                                                                   | 34        |
| 5.1.4 Huấn luyện mô hình <i>Machine learning</i> .....                                                  | 35        |
| 5.1.5 Huấn luyện mô hình <i>Deep Learning</i> .....                                                     | 36        |
| 5.1.6 Huấn luyện mô hình tối ưu <i>XGBoost</i> .....                                                    | 40        |
| 5.2 So sánh kết quả.....                                                                                | 41        |
| 5.3 Dự đoán và đánh giá .....                                                                           | 42        |
| 5.4 Phân tích mô hình <i>Random Forest</i> ( <i>Feature importance</i> và sai số <i>Residuals</i> ).... | 48        |
| 5.4.1 Mục tiêu.....                                                                                     | 48        |
| 5.4.2 Nguyên tắc <i>Feature Importance</i> trong <i>Random Forest</i> .....                             | 48        |
| 5.4.3 Kết quả .....                                                                                     | 49        |
| <b>CHƯƠNG 6. MỞ RỘNG.....</b>                                                                           | <b>53</b> |

|                                                      |           |
|------------------------------------------------------|-----------|
| 6.1 Mục tiêu .....                                   | 53        |
| 6.2 Quy trình thực hiện .....                        | 53        |
| 6.3 Kết quả thực nghiệm .....                        | 54        |
| 6.4 Kết luận .....                                   | 61        |
| <b>CHƯƠNG 7. DEMO WEBSITE HỆ THỐNG DỰ ĐOÁN .....</b> | <b>63</b> |
| 7.1 Mục tiêu .....                                   | 63        |
| 7.2 Tổng quan giao diện.....                         | 63        |
| 7.3 Hướng dẫn sử dụng .....                          | 65        |
| 7.4 Ý nghĩa .....                                    | 68        |
| <b>TÀI LIỆU THAM KHẢO .....</b>                      | <b>70</b> |



## DANH MỤC HÌNH VẼ

|                                                    |    |
|----------------------------------------------------|----|
| Hình 2.1 Dataset được sử dụng .....                | 5  |
| Hình 2.2 Phân bố giá trị RUL .....                 | 9  |
| Hình 2.3 RUL theo chu kỳ sử dụng .....             | 10 |
| Hình 2.4 Ma trận tương quan giữa các biến.....     | 11 |
| Hình 3.1 Kiểm tra giá trị thiếu .....              | 12 |
| Hình 3.2 Xử lý giá trị ngoại lai .....             | 14 |
| Hình 3.3 Lưu dữ liệu .....                         | 14 |
| Hình 3.4 Biểu đồ so sánh xử lý dữ liệu nhiều ..... | 15 |
| Hình 4.1 Linear Regression là gì.....              | 16 |
| Hình 4.2 Random Forest là gì .....                 | 19 |
| Hình 4.3 XGBoost là gì.....                        | 21 |
| Hình 4.4 LSTM là gì .....                          | 24 |
| Hình 4.5 GRU là gì .....                           | 26 |
| Hình 4.6 CNN là gì .....                           | 28 |
| Hình 5.1 Import thư viện sử dụng .....             | 31 |
| Hình 5.2 Kích thước dữ liệu.....                   | 32 |
| Hình 5.3 Dữ liệu sau khi xử lý Feature .....       | 33 |
| Hình 5.4 Xử lý dữ liệu lỗi sau Feature .....       | 34 |
| Hình 5.5 Chia dữ liệu huấn luyện .....             | 34 |
| Hình 5.6 Huấn luyện mô hình Linear Regression..... | 35 |
| Hình 5.7 Huấn luyện mô hình Random Forest .....    | 36 |
| Hình 5.8 Chuyển đổi dữ liệu chuỗi .....            | 37 |

|                                                               |    |
|---------------------------------------------------------------|----|
| Hình 5.9 Hàm đánh giá mô hình .....                           | 37 |
| Hình 5.10 Huấn luyện mô hình LSTM .....                       | 38 |
| Hình 5.11 Huấn luyện mô hình GRU .....                        | 39 |
| Hình 5.12 Huấn luyện mô hình CNN .....                        | 40 |
| Hình 5.13 Huấn luyện mô hình XGBoost.....                     | 41 |
| Hình 5.14 So sánh kết quả các mô hình.....                    | 42 |
| Hình 5.15 Biểu đồ giá trị thực và giá trị đoán.....           | 43 |
| Hình 5.16 Biểu đồ phân bố lỗi .....                           | 43 |
| Hình 5.17 Biểu đồ so sánh theo chu kỳ thời gian .....         | 44 |
| Hình 5.18 Biểu đồ so sánh RMSE, MAE, R2.....                  | 44 |
| Hình 5.19 Dự đoán kết quả .....                               | 45 |
| Hình 5.20 Dự đoán kết quả chi tiết .....                      | 46 |
| Hình 5.21 Ba mô hình tốt nhất.....                            | 47 |
| Hình 5.22 Hiệu suất các mô hình .....                         | 48 |
| Hình 5.23 Feature importance (Top 20) của Random Forest ..... | 50 |
| Hình 5.24 Phân bố sai số.....                                 | 51 |
| Hình 6.1 Kết quả với các mô hình học máy.....                 | 54 |
| Hình 6.2 Kết quả mô hình LSTM .....                           | 55 |
| Hình 6.3 Kết quả mô hình CNN.....                             | 56 |
| Hình 6.4 Kết quả mô hình XGBoost.....                         | 56 |
| Hình 6.5 So sánh kết quả các mô hình.....                     | 57 |
| Hình 6.6 Dự đoán kết quả .....                                | 58 |
| Hình 6.7 Hiệu suất 3 mô hình .....                            | 58 |

|                                          |    |
|------------------------------------------|----|
| Hình 6.8 Feature Importance.....         | 59 |
| Hình 6.9 Residuals .....                 | 60 |
| Hình 7.1 Giao diện hệ thống .....        | 63 |
| Hình 7.2 Giao diện tải file dữ liệu..... | 64 |
| Hình 7.3 Nhập dữ liệu thủ công.....      | 65 |
| Hình 7.4 Kết quả phân tích .....         | 66 |
| Hình 7.5 Dữ liệu phân tích.....          | 66 |
| Hình 7.6 Nhập dữ liệu tải file csv ..... | 67 |
| Hình 7.7 Kết quả dự đoán trên file.....  | 67 |
| Hình 7.8 Dữ liệu xử lý chi tiết .....    | 68 |
| Hình 7.9 Tải kết quả phân tích.....      | 68 |

## **DANH MỤC BẢNG BIỂU**

|                                          |   |
|------------------------------------------|---|
| Bảng 1 Mô tả đặc trưng của dữ liệu ..... | 7 |
|------------------------------------------|---|

## DANH MỤC CÁC CHỮ VIẾT TẮT

|       |                              |
|-------|------------------------------|
| RUL   | Remaining Useful Life        |
| IOT   | Internet of Things           |
| RMSE  | Root Mean Squared Error      |
| MAE   | Mean Absolute Error          |
| $R^2$ | Coefficient of Determination |
| OLS   | Ordinary Least Squares       |

# CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI

## 1.1 Lý do chọn đề tài

Trong những năm gần đây, pin Lithium-ion (Li-on) trở thành nền tảng lưu trữ năng lượng chủ đạo trong rất nhiều hệ thống thiết bị hiện đại, từ điện thoại thông minh, laptop, xe điện (EV), robot tự hành cho đến các hệ thống năng lượng tái tạo. Tính ổn định và tuổi thọ của pin Li-ion ảnh hưởng trực tiếp đến độ tin cậy, hiệu suất cũng như chi phí vận hành của toàn bộ hệ thống. Tuy nhiên, pin Li-ion là một dạng thiết bị tiêu hao nghĩa là hiệu suất sẽ giảm dần theo thời gian do quá trình lão hóa tự nhiên và tác động từ điều kiện sử dụng. Khi pin suy giảm đến một mức nhất định, thiết bị có thể gặp nhiều vấn đề như sụt áp đột ngột, giảm công suất, tăng thời gian sạc hoặc thậm chí gây nguy cơ mất an toàn. Vì vậy, việc dự đoán thời gian sử dụng còn lại của pin (Remaining Useful Life – RUL) đóng vai trò vô cùng quan trọng trong công tác bảo trì dự đoán (predictive maintenance) và tối ưu hóa vận hành.

Bài toán dự đoán RUL đang trở thành xu hướng nghiên cứu rộng rãi trong lĩnh vực Machine Learning và hệ thống IoT, đặc biệt trong bối cảnh các thiết bị ngày càng đòi hỏi khả năng hoạt động liên tục và ổn định. Khi có khả năng ước lượng chính xác RUL, hệ thống có thể chủ động lập kế hoạch thay thế pin, hạn chế thời gian chết (downtime), giảm thiểu hỏng hóc bất thường và tiết kiệm chi phí bảo trì. Đây cũng là một thành phần quan trọng đối với các ngành công nghiệp đòi hỏi độ chính xác cao như hàng không, sản xuất tự động, xe điện, hay các hệ thống cảm biến chạy pin trong môi trường ngoài trời.

Từ các phân tích trên, có thể thấy rằng việc dự đoán thời gian hoạt động còn lại của pin Li-on không chỉ mang ý nghĩa học thuật mà còn có giá trị ứng dụng thực tế rất cao, vừa tạo điều kiện để áp dụng toàn diện kiến thức về trí tuệ nhân tạo và phân tích dữ liệu. Đây là một bài toán điển hình trong predictive maintenance, đề tài vừa giúp khai thác lợi thế của dữ liệu cảm biến để hiểu rõ hơn quá trình lão hóa pin, vừa tạo cơ hội áp dụng các kỹ thuật học máy nhằm giải quyết một vấn đề thực tiễn. Vì thế

việc nghiên cứu mô hình dự đoán RUL của pin Li-on là thiết thực và có khả năng phát triển mở rộng trong tương lai.

## 1.2 Mục tiêu thực hiện đề tài

Mục tiêu cốt lõi của đề tài là xây dựng một hệ thống có khả năng dự đoán chính xác thời gian hoạt động còn lại (RUL) của pin Li-on dựa trên các thông số đo đạc trong quá trình vận hành, thông qua việc khai thác từ bộ dữ liệu đề tài hướng tới việc thiết kế một quy trình phân tích và mô hình hóa toàn diện, ngoài ra đề tài còn hướng đến việc phát triển một giao diện minh họa trực quan giúp mô phỏng môi trường sử dụng thực tế, giúp đánh giá khả năng triển khai mô hình. Kết quả đạt được sẽ giúp hiểu rõ hơn về mối quan hệ giữa các tham số vận hành của pin và mức độ suy giảm tuổi thọ của chúng, đồng thời chứng minh khả năng áp dụng các phương pháp học máy vào bài toán bảo trì dự đoán trong thực tế. Cụ thể các mục tiêu chính như sau:

- Phân tích và tổng hợp cơ sở lý thuyết nền liên quan đến hoạt động và quá trình lão hóa của pin Li-on cùng với các yếu tố ảnh hưởng đến tuổi thọ pin, đồng thời tổng hợp các phương pháp dự đoán RUL phổ biến, từ mô hình hồi quy truyền thống đến các thuật toán học máy. Đây là cơ sở lý luận giúp lựa chọn hướng tiếp cận phù hợp cho việc dự đoán thời gian hoạt động còn lại của pin.
- Xây dựng mô hình dự đoán RUL dựa trên dữ liệu từ bộ dataset, tiến hành các bước làm sạch, chuẩn hóa và tách dữ liệu phục vụ quá trình huấn luyện mô hình. Nhiều mô hình được thử nghiệm để tìm ra mô hình có độ chính xác tốt nhất.
- Thiết kế hệ thống và giao diện minh họa giúp người dùng nhập thông số pin và nhận được kết quả, giao diện được thiết kế trực quan hiển thị đủ các trường dữ liệu đầu vào và kết quả đầu ra cũng như biểu đồ.
- Đánh giá hiệu suất mô hình bằng các thước đo như RMSE, MAE,  $R^2$  để xác định mức độ chính xác của dự đoán và nhận diện được ưu điểm, hạn chế và mức độ ổn định của mô hình.

- Khả năng mở rộng đề xuất với việc bổ sung đặc trưng hoặc áp dụng các kiến trúc học sâu. Hệ thống minh họa có thể được phát triển thành ứng dụng web hoặc tích hợp vào các thiết bị IOT để dự đoán theo thời gian thực.

### **1.3 Đối tượng và phạm vi nghiên cứu**

- Đối tượng nghiên cứu: đối tượng nghiên cứu của đề tài là quá trình suy giảm và tuổi thọ còn lại của pin Lithium-on, được biểu diễn thông qua các thông số vận hành được ghi nhận trong dữ liệu như điện áp cực đại, điện áp cực tiểu, thời gian sạc, thời gian giữ áp và các đặc trưng liên quan. Đồng thời đề tài nghiên cứu các mô hình học máy có khả năng dự đoán RUL dựa trên các đặc trưng này.
- Phạm vi nghiên cứu: tập trung vào việc sử dụng bộ dữ liệu công khai (Battery Remaining Useful Life – Kaggle) mà không tiến hành thu thập dữ liệu thực nghiệm. Mô hình dự đoán được sử dụng bao gồm các nhóm thuật toán hồi quy truyền thống và các mô hình kiến trúc học sâu cơ bản. Bên cạnh đó giao diện minh họa chỉ được xây dựng ở mức mô phỏng chức năng dự đoán.

### **1.4 Ý nghĩa khoa học và thực tiễn của đề tài**

- Về ý nghĩa khoa học, đề tài góp phần làm rõ mối quan hệ giữa các thông số vận hành của pin Li-ion và mức độ suy giảm tuổi thọ của chúng, từ đó đánh giá khả năng ứng dụng các thuật toán học máy trong việc dự đoán Remaining Useful Life (RUL). Mô hình và quy trình được xây dựng có thể làm cơ sở tham khảo cho các nghiên cứu tiếp theo, đặc biệt trong lĩnh vực quản lý năng lượng và bảo trì dự đoán.
- Về ý nghĩa thực tiễn, kết quả dự đoán RUL giúp hệ thống chủ động theo dõi tình trạng pin, hạn chế các sự cố bất ngờ và tối ưu thời gian thay thế hoặc bảo trì thiết bị. Các ứng dụng tiềm năng của đề tài trải rộng từ thiết bị di động, cảm biến IoT, robot tự hành cho đến xe điện và hệ thống lưu trữ



năng lượng. Hệ thống giao diện minh họa cũng giúp trình bày trực quan cách mô hình có thể được triển khai trong thực tế, tăng tính ứng dụng và giá trị thực hành của đề tài.


## CHƯƠNG 2. PHÂN TÍCH DỮ LIỆU VÀ TRỰC QUAN HÓA DỮ LIỆU

### 2.1 Phân tích dữ liệu sử dụng

#### 2.1.1 Giới thiệu và mô tả bộ dữ liệu

Bộ dữ liệu được sử dụng trong đề tài là Battery Remaining Useful Life (RUL) được công bố bởi Ignacio Vinuales trên nền tảng Kaggle, đây là tập dữ liệu được tổng hợp nhằm phục vụ mục tiêu nghiên cứu dự đoán tuổi thọ còn lại của pin Lithium-ion dựa trên các thông số đo đặc theo từng chu kỳ sử dụng. Dataset mô phỏng quá trình vận hành và suy giảm năng lượng của pin dưới điều kiện kiểm soát trong phòng thí nghiệm, theo đúng quy trình sạc xả của các cell pin Li-ion.

Tổng quan về dữ liệu: bộ dữ liệu bao gồm 9 cột như bên dưới



Hình 2.1 Dataset được sử dụng

Mô tả thông tin về các cột của bộ dữ liệu như sau:

| Feature | Mô tả | Giải thích |
|---------|-------|------------|
|---------|-------|------------|

|                           |                                            |                                                                                                        |
|---------------------------|--------------------------------------------|--------------------------------------------------------------------------------------------------------|
| Cycle_Index               | Số thứ tự chu kỳ vận hành của pin          | Cho biết sau bao nhiêu chu kỳ sạc – xả pin đang được theo dõi, dùng để đánh giá mức độ sử dụng.        |
| Discharge Time(s)         | Thời gian xả pin trong chu kỳ (giây)       | Thời gian pin xả từ trạng thái sạc đến ngưỡng chuẩn – thời gian càng ngắn có thể phản ánh suy giảm.    |
| Decrement 3.6-3.4V (s)    | Thời gian sụt áp từ 3.6V xuống 3.4V (giây) | Thời gian pin tự sụt từ 3.6V xuống 3.4V trong quá trình xả, rất quan trọng để đánh giá lão hóa pin.    |
| Max.Voltage Dischar.(V)   | Điện áp cực đại khi xả pin (V)             | Điện áp cao nhất đo được trong quá trình xả cho thấy mức hiệu quả xả pin.                              |
| Min. Voltage Charg. (V)   | Điện áp cực tiểu khi sạc pin (V)           | Điện áp thấp nhất khi pin sạc càng thấp có thể nói lên pin mất khả năng giữ điện tốt như ban đầu.      |
| Time at 4.15V (s)         | Thời gian giữ điện áp ở 4.15V (giây)       | Mô tả khoảng thời gian pin duy trì được điện áp 4.15V, thể hiện hiệu suất sạc/xả và trạng thái pin.    |
| Time constant current (s) | Hằng số thời gian dòng điện duy trì (giây) | Thông số thời gian mà dòng điện gần như ổn định khi sạc hoặc xả có thể phản ánh đặc tính điện hóa pin. |
| Charging time (s)         | Thời gian sạc pin trong chu kỳ (giây)      | Tổng thời gian sạc từ đầu đến khi hoàn tất thể hiện khả năng phục hồi của pin.                         |

| RUL | Tuổi thọ còn lại của pin là biến mục tiêu | Biến mục tiêu cần dự đoán cho biết pin còn có thể sử dụng bao lâu trước khi cần thay thế. |
|-----|-------------------------------------------|-------------------------------------------------------------------------------------------|
|-----|-------------------------------------------|-------------------------------------------------------------------------------------------|

Bảng 1 Mô tả đặc trưng của dữ liệu

### 2.1.2 Khám phá dữ liệu ban đầu

Trong giai đoạn đầu tiên, việc khám phá dữ liệu giúp hình dung tổng quan về những gì bộ dữ liệu cung cấp và mức độ đầy đủ của thông tin phục vụ bài toán dự đoán RUL. Từ kích thước bộ dữ liệu đến danh sách các thuộc tính, những quan sát ban đầu này cho thấy dữ liệu đã ghi lại nhiều đặc trưng quan trọng phản ánh trạng thái vận hành của pin theo từng chu kỳ. Thông qua việc xem xét trực tiếp một số bản ghi đầu tiên, nhóm nghiên cứu có được cái nhìn rõ ràng về cách dữ liệu được tổ chức, định dạng giá trị và mức độ nhất quán của thông tin.

Bên cạnh việc hiểu cấu trúc, giai đoạn này còn giúp đánh giá sơ bộ xu hướng của biến mục tiêu RUL thông qua quan sát phân bố giá trị và sự thay đổi của RUL theo số chu kỳ hoạt động. Những đặc điểm ban đầu này cho thấy tuổi thọ pin giảm dần theo quá trình sử dụng, phù hợp với quy luật lão hóa của pin Li-ion. Đồng thời, việc phát hiện các dấu hiệu bất thường hay sự phân tán mạnh của các giá trị cũng là cơ sở quan trọng để chuẩn bị cho bước tiền xử lý dữ liệu ở chương sau, giúp mô hình học máy có đầu vào sạch và ổn định hơn.

### 2.1.3 Phân tích mối quan hệ giữa các đặc trưng

Các đặc trưng trong bộ dữ liệu đều là những thông số đo đạc liên quan trực tiếp đến quá trình sạc – xả và sự suy giảm hiệu năng của pin Li-ion theo thời gian. Vì vậy, giữa chúng tồn tại nhiều mối quan hệ logic phản ánh trạng thái điện hóa của pin

- Đặc trưng **Cycle\_Index** có quan hệ chặt chẽ với sự suy giảm của pin, bởi số chu kỳ sử dụng càng lớn thì tuổi thọ còn lại (**RUL**) càng thấp. Đây là


quy luật lão hóa tự nhiên của pin, và là mối quan hệ mạnh nhất trong toàn bộ tập dữ liệu.

- Bên cạnh đó, các thông số như **Discharge Time**, **Decrement 3.6–3.4V**, **Max Voltage Discharge** hay **Min Voltage Charge** đều phản ánh hiệu suất của pin trong từng chu kỳ. Khi pin lão hóa, thời gian xả thường giảm, tốc độ sụt áp nhanh hơn và các giá trị điện áp cực đại hoặc cực tiểu có xu hướng thay đổi không ổn định. Điều này tạo ra sự liên hệ gián tiếp với RUL, cho thấy những đặc trưng liên quan đến điện áp và thời gian xả/sạc đều góp phần mô tả mức độ suy giảm của pin.
- Ngoài ra, các đặc trưng về thời gian như **Time at 4.15V**, **Charging Time** và **Time Constant Current** cũng có mối liên hệ với nhau. Chúng đều phản ánh khả năng hấp thụ và duy trì điện tích của pin trong quá trình sạc. Khi pin suy giảm, các thời gian này có xu hướng thay đổi theo hướng kém ổn định, cho thấy pin giữ điện kém hơn hoặc cần nhiều thời gian hơn để hoàn tất quá trình sạc. Mối quan hệ giữa các thông số này góp phần bổ sung thông tin cho việc đánh giá tình trạng pin bên cạnh chu kỳ vận hành.
- Tổng thể, các đặc trưng trong bộ dữ liệu có mối quan hệ khá chặt chẽ, cùng mô tả quá trình lão hóa theo thời gian và đều có giá trị nhất định trong bài toán dự đoán RUL. Những quan hệ này đóng vai trò quan trọng trong việc lựa chọn đầu vào phù hợp cho mô hình và hiểu cách các đặc trưng góp phần thể hiện trạng thái thực tế của pin.

## 2.2 Trực quan hóa dữ liệu

### 2.2.1 Trực quan hóa phân bố của RUL

Để hiểu rõ hơn về đặc điểm của biến mục tiêu trong bài toán, tiến hành trực quan hóa phân bố giá trị RUL trong toàn bộ tập dữ liệu. Biểu đồ sẽ giúp đánh giá mức độ trải rộng của các giá trị, sự tập trung của dữ liệu tại các vùng nhất định và tính ổn định của biến mục tiêu. Nhằm xác định độ khó của bài toán hồi quy và chuẩn bị cho quá trình huấn luyện mô hình.




Hình 2.2 Phân bố giá trị RUL

Quan sát biểu đồ cho thấy giá trị RUL trải đều trên một dải rộng, dao động từ mức cao đến mức thấp mà không xuất hiện sự lệch lớn về phân bố. Tần suất xuất hiện ở mỗi khoảng giá trị tương đối đồng đều, cho thấy dữ liệu mục tiêu không bị mất cân bằng nghiêm trọng, giúp mô hình có khả năng học tốt hơn vì dữ liệu mục tiêu phân bố rộng, phản ánh đầy đủ các trạng thái tuổi thọ của pin.

### 2.2.2 *Trực quan hóa xu hướng RUL theo số chu kỳ hoạt động*

Bên cạnh phân bố tổng thể, việc quan sát sự thay đổi của RUL theo số chu kỳ sử dụng là yếu tố then chốt để hiểu quy luật suy giảm của pin. Biểu đồ đường giữa Cycle\_Index và RUL cho phép theo dõi trực quan quá trình lão hóa của pin trong suốt vòng đời vận hành. Biểu đồ này cho thấy rõ mức độ phụ thuộc của RUL vào thời gian sử dụng.




Hình 2.3 RUL theo chu kỳ sử dụng

Biểu đồ cho thấy RUL giảm gần như tuyến tính khi số chu kỳ tăng lên, phản ánh rõ quy luật lão hóa của pin Li-ion theo thời gian. Đường xu hướng giảm đều chứng minh rằng tuổi thọ pin bị hao mòn một cách ổn định sau mỗi chu kỳ sạc – xả. Mối quan hệ tuyến tính này là tín hiệu tốt cho mô hình hồi quy, vì nó giúp mô hình dễ dàng học được quy luật suy giảm tuổi thọ còn lại.

### ***2.2.3 Trực quan hóa ma trận tương quan giữa các đặc trưng***

Để đánh giá mối liên hệ giữa các đặc trưng, sử dụng ma trận tương quan nhằm đo lường mức độ ảnh hưởng giữa từng cặp biến. Việc trực quan hóa bằng heatmap giúp nhận diện nhanh các đặc trưng có liên quan chặt chẽ với nhau cũng như với biến mục tiêu RUL.



Hình 2.4 Ma trận tương quan giữa các biến

Heatmap cho thấy Cycle\_Index có tương quan âm rất mạnh với RUL, điều này phù hợp với thực tế khi số chu kỳ sử dụng càng lớn thì tuổi thọ còn lại càng giảm. Ngoài ra, một số đặc trưng như Discharge Time, Time Constant Current hay Charging Time thể hiện mức tương quan cao với nhau, phản ánh mối liên hệ giữa các quá trình sạc – xả của pin. Những yếu tố này giúp xác định các đặc trưng quan trọng cho mô hình và tránh sử dụng những đặc trưng mang tính trùng lặp cao gây nhiễu cho quá trình học.



## CHƯƠNG 3. XỬ LÝ TẬP DỮ LIỆU

### 3.1 Kiểm tra và xử lý giá trị thiếu (Missing Values)

Việc kiểm tra giá trị thiếu giúp đảm bảo dữ liệu đầu vào hoàn chỉnh, không sai lệch trong quá trình mô hình hóa, đây là bước đầu tiên để đánh giá chất lượng dữ liệu thô.

- Mục đích: nếu dữ liệu không bị thiếu thì không cần thực hiện bước làm đầy dữ liệu và đảm bảo quá trình xử lý và huấn luyện mô hình sẽ không bị ảnh hưởng bởi dữ liệu thiếu.
- Kết quả kiểm tra giá trị thiếu:

---

```
Missing values per column:
Cycle_Index                0
Discharge Time (s)         0
Decrement 3.6–3.4V (s)     0
Max. Voltage Dischar. (V)  0
Min. Voltage Charg. (V)    0
Time at 4.15V (s)          0
Time constant current (s)  0
Charging time (s)          0
RUL                        0
..
```

Hình 3.1 Kiểm tra giá trị thiếu

Tuy nhiên, trong dữ liệu cảm biến hoặc đo đạc, nếu thiếu dữ liệu không chỉ đến từ việc ô trống, mà còn xuất hiện khi dữ liệu chứa giá trị không hợp lệ. Do đó, áp dụng bước kiểm tra tính hợp lệ theo ngữ nghĩa (validation) đối với các cột thời gian, vì về mặt vật lý các đại lượng thời gian không thể nhỏ hơn hoặc bằng 0. Cụ thể, với các cột thời gian như: Discharge Time (s), Decrement 3.6–3.4V (s), Time at 4.15V (s), Time constant current (s), Charging time (s), những giá trị  $\leq 0$  được xem là bất thường và được chuyển về NaN để xử lý ở các bước tiếp theo.

Sau bước kiểm tra hợp lệ, dữ liệu có thể phát sinh thêm các vị trí NaN (tức missing values sau làm sạch). Thay vì điền giá trị theo trung bình/trung vị một cách

độc lập tại từng điểm, thiêu tiên phương pháp phù hợp với tính chất chuỗi theo Cycle\_Index: nội suy tuyến tính (linear interpolation). Phương pháp này ước lượng giá trị bị khuyết dựa trên hai điểm lân cận trước và sau, giúp tín hiệu giữ được tính liên tục và phản ánh hợp lý xu hướng suy giảm của pin theo chu kỳ.

Kết quả sau khi nội suy cho thấy bộ dữ liệu không còn giá trị thiếu và sẵn sàng cho bước xử lý ngoại lai cũng như huấn luyện mô hình.

### 3.2 Xử lý giá trị ngoại lai (Outliers)

Ngoại lai (outliers) là các điểm dữ liệu có giá trị bất thường so với phần còn lại của tập dữ liệu, thường phát sinh do lỗi cảm biến, lỗi ghi nhận hoặc điều kiện đo không ổn định. Nếu không xử lý, các điểm này có thể làm mô hình học sai, gây sai lệch tham số và giảm độ ổn định khi dự đoán. Sẽ có 2 mức độ:

- Ngoại lai toàn cục (Global Outliers): Một số giá trị có thể siêu lớn và không phản ánh trạng thái thực của pin. Thay vì cắt ngưỡng trực tiếp (clipping) làm dữ liệu bị bẹt, nhóm coi các điểm vượt ngưỡng là mất dữ liệu và chuyển về NaN để nội suy lại. Ngưỡng được xác định theo phân vị cao (quantile) cụ thể sử dụng quantile 0.995 cho các cột thời gian. Các điểm nằm trong nhóm cao nhất vượt ngưỡng này được xem là nhiễu cực đoan và loại khỏi chuỗi dữ liệu bằng cách gán NaN.
- Ngoại lai cục bộ theo chu kỳ (Local Outliers): Do dữ liệu được ghi nhận theo Cycle\_Index và phản ánh quá trình pin lão hóa theo thời gian, tín hiệu kỳ vọng có xu hướng biến thiên tương đối mượt. Vì thế thực hiện xử lý nhiễu cục bộ dựa trên ý tưởng: nếu một điểm lệch quá xa so với xu hướng lân cận gần nhất thì điểm đó nhiều khả năng là nhiễu.

Quy trình thực hiện bao gồm:

- Sắp xếp dữ liệu theo Cycle\_Index để đảm bảo đúng thứ tự thời gian.
- Tính trung vị trượt (Rolling Median) trên một cửa sổ lân cận (window).
- Tính độ lệch tương đối giữa giá trị hiện tại và trung vị trượt.
- Nếu độ lệch tương đối vượt ngưỡng, điểm đó được gán NaN.

Dữ liệu sau xử lý giảm nhiễu rõ rệt và nhất quán hơn với quy luật suy giảm của pin. Sau khi đánh dấu outliers bằng NaN, nhóm tiếp tục sử dụng nội suy tuyến tính để điền lại các điểm bị khuyết nhằm đảm bảo chuỗi dữ liệu không bị đứt đoạn.

Cột Discharge Time (s): Đã loại bỏ 114 điểm dữ liệu bất thường cục bộ.  
 Cột Decrement 3.6–3.4V (s): Đã loại bỏ 52 điểm dữ liệu bất thường cục bộ.  
 Cột Max. Voltage Dischar. (V): Đã loại bỏ 0 điểm dữ liệu bất thường cục bộ.  
 Cột Min. Voltage Charg. (V): Đã loại bỏ 0 điểm dữ liệu bất thường cục bộ.  
 Cột Time at 4.15V (s): Đã loại bỏ 243 điểm dữ liệu bất thường cục bộ.  
 Cột Time constant current (s): Đã loại bỏ 205 điểm dữ liệu bất thường cục bộ.  
 Cột Charging time (s): Đã loại bỏ 158 điểm dữ liệu bất thường cục bộ.

Kích thước sau xử lý: (15064, 9)

Hình 3.2 Xử lý giá trị ngoại lai

Sau khi xử lý ngoại lai, kích thước dữ liệu giảm từ 16506 còn 15064 hàng.

### 3.3 Kiểm tra và lưu dữ liệu


Sau khi thực hiện các thao tác làm sạch và chuẩn hóa, dữ liệu được kiểm tra lại để đảm bảo các bước đã làm trước đó mang lại hiệu quả, kích thước dữ liệu được theo dõi để xác nhận quá trình xử lý không làm mất dữ liệu quan trọng, đồng thời thống kê mô tả của các đặc trưng được in ra nhằm quan sát lại để kiểm tra sự thay đổi. Cuối cùng bộ dữ liệu được lưu vào một tệp mới nhằm tách bạch giữa dữ liệu thô và dữ liệu đã xử lý.

Thống kê mô tả sau khi làm sạch (hợp lý hơn):

|       | Discharge Time (s) | Decrement 3.6–3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) |
|-------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|
| count | 15064.000000       | 15064.000000           | 15064.000000              | 15064.000000            | 15064.000000      | 15064.000000              | 15064.000000      |
| mean  | 2431.494567        | 522.232835             | 3.908176                  | 3.577904                | 3215.651277       | 4146.187166               | 8641.906719       |
| std   | 11948.500108       | 1436.811036            | 0.091003                  | 0.123695                | 3675.177157       | 4755.914947               | 4476.833081       |
| min   | 34.380000          | 38.709677              | 3.043000                  | 3.022000                | 255.241143        | 8.000000                  | 8.380000          |
| 25%   | 1168.717500        | 320.000000             | 3.846000                  | 3.488000                | 1834.027286       | 2564.310000               | 7837.535000       |
| 50%   | 1555.380000        | 438.857143             | 3.906000                  | 3.574000                | 2924.359000       | 3788.380000               | 8313.235000       |
| 75%   | 1906.675000        | 598.400000             | 3.972000                  | 3.663000                | 4076.344000       | 5012.320000               | 8756.360000       |
| max   | 197940.480000      | 86584.925500           | 4.363000                  | 4.379000                | 62910.013000      | 78270.020000              | 78660.000000      |

Hình 3.3 Lưu dữ liệu

Vẽ biểu đồ so sánh nhanh thể hiện việc dữ liệu trước và sau khi xử lý nhiễu.




Hình 3.4 Biểu đồ so sánh xử lý dữ liệu nhiễu

## CHƯƠNG 4. CÁC MÔ HÌNH ĐƯỢC SỬ DỤNG TRONG BÀI TOÁN

### 4.1 Các mô hình học máy (Machine Learning)

#### 4.1.1 Mô hình *Linear Regression*

Cơ sở lý thuyết: Hồi quy tuyến tính (Linear Regression) là một trong những thuật toán cơ bản nhất trong học máy có giám sát. Mô hình này đơn giản nhưng đã chứng minh được tính hữu ích trong rất nhiều tình huống thực tế. Về bản chất, hồi quy tuyến tính là một phương pháp thống kê nhằm thiết lập mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập. Mục tiêu của mô hình là xây dựng phương trình tuyến tính mô tả sự thay đổi của Y theo X từ đó dự đoán giá trị Y dựa trên các giá trị của X.



Hình 4.1 Linear Regression là gì

#### Ưu điểm của Linear Regression:

- **Đơn giản, dễ hiểu:** Hồi quy tuyến tính có nền tảng toán học đơn giản và kết quả của mô hình dễ diễn giải. Người phân tích và cả những người không

chuyên sâu về kỹ thuật cũng có thể hiểu được ý nghĩa của các hệ số một cách trực quan.

- **Tính hiệu quả và nhanh chóng:** Việc ước lượng tham số bằng OLS có thể thực hiện nhanh nhờ công thức giải tích trực tiếp. Mô hình hồi quy tuyến tính cũng ít yêu cầu tài nguyên tính toán hơn so với nhiều mô hình phức tạp khác, đặc biệt hữu ích khi làm việc với dữ liệu lớn mà quan hệ gần như tuyến tính. Hơn nữa, mô hình cho phép phân tích mối quan hệ giữa các biến một cách trực tiếp và hiệu quả, giúp đưa ra dự đoán nhanh về  $Y$  dựa trên  $X$ .
- **Kiểm định giả thuyết và suy luận thống kê:** Mô hình hồi quy tuyến tính có một nền tảng lý thuyết thống kê vững chắc, cho phép thực hiện các kiểm định ý nghĩa (như kiểm định  $t$  cho từng hệ số, kiểm định  $F$  cho mô hình) và xây dựng các khoảng tin cậy cho tham số. Nhờ giả định phân phối chuẩn của sai số, ta có thể đánh giá được biến nào có ý nghĩa thống kê, mô hình có ý nghĩa hay không,... Đây là ưu điểm giúp hồi quy tuyến tính không chỉ dự đoán mà còn dùng để giải thích mối quan hệ trong dữ liệu một cách định lượng.

#### **Nhược điểm của Linear Regression:**

- **Nhạy cảm với ngoại lệ (outliers):** Phương pháp OLS dùng bình phương sai số nên những điểm dữ liệu bất thường có sai số lớn sẽ ảnh hưởng mạnh đến mô hình. Chỉ một vài outlier có thể kéo lệch đường hồi quy đáng kể, làm sai lệch các hệ số ước lượng. Do đó, mô hình tuyến tính không robust (không chống chịu tốt) với ngoại lệ. Trước khi hồi quy, thường cần phát hiện và xử lý các outlier (loại bỏ hoặc sử dụng phương pháp hồi quy bền vững hơn) để mô hình ổn định.
- **Nguy cơ overfitting khi dùng quá nhiều biến:** Mặc dù mô hình tuyến tính bản thân nó không quá phức tạp, nhưng nếu đưa vào mô hình quá nhiều biến độc lập so với số lượng dữ liệu thì vẫn có nguy cơ overfitting (mô hình khớp quá sát dữ liệu nhiễu). Lúc đó mô hình sẽ dự đoán kém trên

dữ liệu mới. Cần áp dụng các kỹ thuật chọn biến, cross-validation để đảm bảo mô hình không bị quá khớp và giữ được khả năng tổng quát hóa.

- **Yêu cầu dữ liệu độc lập:** Mô hình giả định các quan sát là độc lập. Trong nhiều trường hợp dữ liệu thực tế, các điểm dữ liệu có thể có quan hệ với nhau (ví dụ: dữ liệu thời gian, dữ liệu theo nhóm). Nếu vi phạm giả định độc lập (tức có tự tương quan hoặc cấu trúc phụ thuộc), các ước lượng OLS vẫn không chệch nhưng phương sai tăng, việc suy luận không còn chính xác.

**Ứng dụng trong bài toán dự đoán thời gian hoạt động còn lại của pin Lion:**


- Linear Regression được huấn luyện trên tập train bằng cách ước lượng các trọng số tối ưu theo phương pháp bình phương tối thiểu (Ordinary Least Squares). Vì dữ liệu RUL có xu hướng giảm tuyến tính theo số chu kỳ sử dụng nên mô hình tuyến tính phù hợp để mô phỏng quan hệ này. Sau khi huấn luyện, mô hình được dùng để dự đoán RUL trên tập test, và kết quả dự đoán được so sánh với giá trị thực thông qua các chỉ số đánh giá như RMSE, MAE và  $R^2$ .

#### **4.1.2 Mô hình *Random Forest***

Cơ sở lý thuyết: Mô hình **Random Forest** là một thuật toán học máy thuộc nhóm học có giám sát, được xây dựng dựa trên nguyên lý học kết hợp (ensemble learning). Thuật toán này tạo ra một “rừng” gồm nhiều cây quyết định độc lập, sau đó tổng hợp kết quả dự đoán của các cây để đưa ra kết luận cuối cùng – bằng cơ chế bỏ phiếu đa số (với phân loại) hoặc trung bình (với hồi quy). Mỗi cây trong rừng được huấn luyện trên một tập con dữ liệu lấy mẫu ngẫu nhiên có hoàn lại (bootstrap), đồng thời tại mỗi nút cây chỉ xét một tập con ngẫu nhiên của các thuộc tính đầu vào, giúp tăng tính đa dạng giữa các cây. Nhờ đó, Random Forest giảm thiểu hiện tượng quá khớp, cải thiện độ chính xác và ổn định của mô hình so với một cây đơn lẻ. Với khả năng xử lý tốt dữ liệu nhiễu, đánh giá được mức độ quan trọng của thuộc tính và hiệu

quả cao trong nhiều loại bài toán, Random Forest trở thành một trong những thuật toán được sử dụng phổ biến nhất trong học máy hiện đại.

## Random Forest



Hình 4.2 Random Forest là gì

### Ưu điểm của Random Forest:

- Random Forest có khả năng giảm hiện tượng quá khớp (overfitting) một cách hiệu quả. Nhờ vào cơ chế lấy mẫu bootstrap và lựa chọn ngẫu nhiên tập thuộc tính tại mỗi nút phân chia, các cây quyết định trong rừng có tính đa dạng cao. Việc kết hợp nhiều cây độc lập giúp làm giảm phương sai của mô hình mà không làm tăng đáng kể độ chệch (bias), từ đó mang lại độ chính xác cao và khả năng tổng quát hóa tốt trên dữ liệu chưa từng thấy.
- mô hình này hoạt động linh hoạt trên nhiều loại dữ liệu khác nhau, kể cả dữ liệu nhiễu hoặc có mối quan hệ phi tuyến giữa các biến đầu vào và đầu ra. Random Forest không yêu cầu chuẩn hóa dữ liệu hoặc xử lý đặc biệt với dữ liệu rời rạc hay liên tục. Ngoài ra, thuật toán có thể xử lý tốt dữ liệu nhiều chiều và còn tích hợp sẵn khả năng đánh giá mức độ quan trọng của các đặc trưng đầu vào, hỗ trợ người dùng trong việc chọn lọc biến hoặc giải thích mô hình tổng quan.
- Random Forest cung cấp ước lượng lỗi ngoài túi (Out-of-Bag error), cho phép đánh giá hiệu suất mô hình ngay trong quá trình huấn luyện mà không



cần tách thêm tập kiểm tra. Điều này không chỉ tiết kiệm dữ liệu mà còn giúp hiệu chỉnh siêu tham số nhanh chóng. Bên cạnh đó, mô hình có thể được song song hóa dễ dàng do các cây hoạt động độc lập, từ đó nâng cao hiệu suất tính toán khi xử lý tập dữ liệu lớn.

#### **Nhược điểm của Random Forest:**

- Mô hình có cấu trúc phức tạp và khó diễn giải. Không giống như một cây quyết định đơn lẻ – vốn dễ trực quan hóa và giải thích theo các quy tắc rõ ràng – Random Forest là sự kết hợp của hàng trăm hoặc hàng nghìn cây, khiến việc theo dõi hoặc giải thích chi tiết quyết định của mô hình trở nên khó khăn. Trong những ứng dụng yêu cầu tính minh bạch và giải thích cao như tài chính hoặc y tế, điều này có thể là một hạn chế đáng kể.
- Do sử dụng nhiều cây, Random Forest đòi hỏi nhiều tài nguyên tính toán hơn so với các mô hình đơn lẻ. Thời gian huấn luyện và dự đoán có thể tăng đáng kể khi số lượng cây lớn hoặc khi áp dụng trên tập dữ liệu có nhiều biến và mẫu. Mặc dù quá trình này có thể được song song hóa, nhưng trong môi trường hạn chế về phần cứng hoặc yêu cầu thời gian thực, chi phí tính toán vẫn có thể là vấn đề cần cân nhắc.
- Random Forest có thể gặp khó khăn với dữ liệu có độ mất cân bằng cao hoặc số chiều rất lớn. Mặc định, mô hình có xu hướng thiên lệch về lớp chiếm đa số trong các bài toán phân loại mất cân bằng. Ngoài ra, trong các trường hợp số lượng đặc trưng quá lớn so với số mẫu, việc chọn ngẫu nhiên các thuộc tính có thể khiến mô hình chọn phải những biến ít liên quan, làm giảm hiệu năng tổng thể. Khi đó, cần áp dụng các kỹ thuật bổ trợ như gán trọng số lớp, chọn lọc thuộc tính hoặc sử dụng các biến thể cải tiến của Random Forest.

#### **Ứng dụng của Random Forest trong bài toán dự đoán thời gian hoạt động còn lại của pin Li-on:**

- Trong quá trình áp dụng, Random Forest được huấn luyện trên tập train bằng cách xây dựng nhiều cây quyết định độc lập. Mỗi cây học trên một

mẫu dữ liệu con được lấy ngẫu nhiên, giúp mô hình giảm thiểu hiện tượng overfitting và tăng tính tổng quát hóa. Sau khi hoàn tất quá trình huấn luyện, mô hình kết hợp dự đoán của tất cả các cây bằng cách lấy trung bình, từ đó tạo ra giá trị dự đoán ổn định và ít nhiễu hơn so với mô hình đơn lẻ.

### 4.1.3 Mô hình XGBoost

Cơ sở lý thuyết: **XGBoost (Extreme Gradient Boosting)** là một thuật toán học máy thuộc nhóm boosting, được phát triển để tối ưu hóa hiệu suất và tốc độ của phương pháp Gradient Boosting Decision Trees (GBDT). Điểm nổi bật của XGBoost nằm ở khả năng huấn luyện nhanh chóng, khả năng tổng quát hóa tốt và tích hợp nhiều cải tiến như xử lý giá trị thiếu, regularization, và tối ưu hóa song song. Đây là một mô hình học có giám sát, có thể áp dụng cho cả bài toán phân loại và hồi quy. XGBoost thường được sử dụng như một mô hình mạnh mẽ cho dữ liệu dạng bảng, và đã giành được nhiều chiến thắng trong các cuộc thi học máy như Kaggle. Nhờ tính linh hoạt và hiệu quả cao, XGBoost đã trở thành một trong những thuật toán được ưa chuộng nhất trong hệ sinh thái machine learning hiện đại.


## WHAT IS XGBOOST?

Stands for:

- eXtreme Gradient Boosting.

XGBoost is a powerful iterative learning algorithm based on gradient boosting.

Robust and highly versatile, with custom objective loss function compatibility.



Hình 4.3 XGBoost là gì

**Ưu điểm của XGBoost:**

- GBoost có khả năng tối ưu hóa hiệu suất mô hình rất cao, nhờ tích hợp nhiều cải tiến như regularization (L1, L2), pruning sớm (early stopping), và shrinkage. Những cơ chế này giúp mô hình không chỉ đạt được độ chính xác vượt trội mà còn tránh được hiện tượng quá khớp, điều mà các mô hình boosting truyền thống thường gặp phải. Ngoài ra, thuật toán còn hỗ trợ tính toán song song ở cấp độ node, giúp giảm đáng kể thời gian huấn luyện trên tập dữ liệu lớn.
- XGBoost được thiết kế với nhiều cơ chế xử lý dữ liệu hiệu quả và thông minh. Mô hình có thể tự động xử lý giá trị thiếu mà không cần tiền xử lý phức tạp, đồng thời hỗ trợ sparsity-aware để hoạt động tốt với dữ liệu thưa (sparse data). Ngoài ra, XGBoost có thể xử lý cả biến liên tục và rời rạc, và đặc biệt hiệu quả với dữ liệu dạng bảng, nơi mà nhiều mô hình deep learning thường không đạt kết quả tốt bằng.
- XGBoost cung cấp khả năng điều chỉnh linh hoạt thông qua hệ thống siêu tham số phong phú như learning rate, max depth, subsample, colsample, lambda, alpha... Điều này giúp người dùng tinh chỉnh mô hình để phù hợp với đặc điểm của từng bài toán cụ thể. Đồng thời, thư viện XGBoost có hỗ trợ nhiều ngôn ngữ (Python, R, Java, Scala) và dễ dàng tích hợp với các công cụ học máy khác như scikit-learn, LightGBM, hay CatBoost, làm tăng khả năng ứng dụng trong thực tế.

#### **Nhược điểm của XGBoost:**

- Là một mô hình phức tạp với nhiều siêu tham số, việc điều chỉnh (tuning) XGBoost có thể mất nhiều thời gian và công sức. Nếu không tinh chỉnh phù hợp, mô hình dễ bị quá khớp hoặc không đạt hiệu năng tối ưu.
- Mặc dù XGBoost mạnh mẽ về hiệu suất, mô hình này khó diễn giải hơn so với các mô hình tuyến tính hoặc cây đơn. Vì là sự kết hợp của nhiều cây con xây dựng tuần tự, nên việc truy ngược lại cách ra quyết định cho một mẫu cụ thể là phức tạp. Điều này gây bất lợi trong các bài toán yêu cầu tính

giải thích cao như y tế, tài chính hoặc pháp lý, nơi cần rõ ràng về lý do mô hình đưa ra quyết định.

- XGBoost có thể tốn tài nguyên tính toán đáng kể, đặc biệt với tập dữ liệu lớn hoặc nhiều đặc trưng. Mặc dù hỗ trợ xử lý song song, việc tạo ra hàng trăm hoặc hàng nghìn cây quyết định vẫn gây áp lực lớn lên CPU và bộ nhớ.

#### **Ứng dụng của XGBoost trong bài toán dự đoán thời gian còn lại của pin Li-ion:**


- Trong dự án, mô hình XGBoost được sử dụng như một phương pháp học máy mạnh nhằm cải thiện độ chính xác trong dự đoán tuổi thọ còn lại (RUL) của pin Li-ion. Sau khi dữ liệu được làm sạch và chuẩn hóa, toàn bộ các đặc trưng đầu vào được sử dụng để huấn luyện mô hình. XGBoost hoạt động theo cơ chế gradient boosting, xây dựng các cây quyết định nhỏ nối tiếp nhau để giảm dần sai số qua từng vòng học. Nhờ khả năng tối ưu dựa trên đạo hàm kết hợp với cơ chế regularization, mô hình có thể mô tả tốt các quan hệ phi tuyến và hạn chế hiện tượng overfitting. Sau khi huấn luyện, XGBoost dự đoán RUL trên tập test và đạt hiệu suất cao, thể hiện tính phù hợp của mô hình với dữ liệu dạng bảng trong bài toán RUL.

## **4.2 Các mô hình học sâu (Deep Learning)**

### **4.2.1 Mô hình Long Short-Term Memory (LSTM)**

Cơ sở lý thuyết: **LSTM (Long Short-Term Memory)** là một kiến trúc mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN) được thiết kế đặc biệt để xử lý dữ liệu tuần tự và khắc phục nhược điểm “quên thông tin dài hạn” của RNN truyền thống. Mô hình LSTM sử dụng cơ chế *bộ nhớ* (memory cell) cùng ba cổng điều khiển – cổng quên, cổng đầu vào và cổng đầu ra – giúp điều chỉnh lượng thông tin cần nhớ hoặc cần loại bỏ theo thời gian. Nhờ đó, LSTM có khả năng nắm bắt quan hệ phụ thuộc dài hạn trong chuỗi, phù hợp với các bài toán như xử lý ngôn ngữ tự nhiên, dịch máy, phân tích cảm xúc hoặc dự báo chuỗi thời gian. Với khả năng mô hình hóa

dữ liệu tuần tự vượt trội, LSTM trở thành nền tảng quan trọng trong nhiều ứng dụng deep learning trước khi các mô hình Transformer ra đời.



Hình 4.4 LSTM là gì

#### Ưu điểm của LSTM:

- LSTM có khả năng ghi nhớ phụ thuộc dài hạn nhờ thiết kế đặc biệt của các cổng điều khiển trong cell. Điều này giúp mô hình vượt qua hạn chế nghiêm trọng của RNN truyền thống là gradient dễ bị biến mất hoặc nổ (vanishing/exploding gradient). Nhờ cơ chế truyền gradient ổn định, LSTM hoạt động tốt trên những chuỗi dài, chẳng hạn văn bản hoặc chuỗi thời gian có độ dài hàng trăm bước.
- Mô hình LSTM mang tính linh hoạt cao khi áp dụng cho nhiều dạng dữ liệu tuần tự. Trong xử lý ngôn ngữ tự nhiên, LSTM có thể học được ngữ cảnh và cấu trúc ngữ nghĩa theo trình tự từ, hỗ trợ tốt cho các tác vụ như phân loại văn bản, sinh câu, gán nhãn chuỗi. Trong dự báo chuỗi thời gian, LSTM có thể học những mẫu (patterns) phức tạp theo thời gian mà các mô hình truyền thống như ARIMA khó xử lý.
- LSTM dễ dàng mở rộng sang các biến thể mạnh hơn như BiLSTM, Stacked LSTM hoặc Seq2Seq LSTM, giúp tăng khả năng học đặc trưng và cải thiện hiệu suất trong các bài toán yêu cầu học sâu. Việc kết hợp LSTM với các

tầng CNN, Attention cũng giúp mô hình thích nghi với nhiều hướng tiếp cận khác nhau, mở rộng không gian ứng dụng trong deep learning.

#### **Nhược điểm của LSTM:**

- LSTM đòi hỏi chi phí tính toán lớn hơn nhiều so với RNN thường hoặc các mô hình tuyến tính. Kiến trúc LSTM sử dụng nhiều ma trận trọng số và cơ chế cổng phức tạp, khiến thời gian huấn luyện dài hơn, nhất là trên tập dữ liệu lớn hoặc chuỗi dài. Điều này làm LSTM khó triển khai trong môi trường tài nguyên hạn chế hoặc yêu cầu thời gian thực.
- Mô hình LSTM vẫn khó nắm bắt quan hệ phụ thuộc rất dài nếu chuỗi quá phức tạp, mặc dù tốt hơn RNN truyền thống. Khi chuỗi văn bản vượt quá vài trăm hoặc vài nghìn bước, LSTM vẫn gặp khó khăn trong việc mô hình hóa toàn bộ ngữ cảnh so với các mô hình hiện đại như Transformer.
- LSTM không dễ diễn giải và khó trực quan hóa các trạng thái ẩn bên trong. Việc hiểu tại sao mô hình dự đoán kết quả A thay vì B không đơn giản, làm giảm tính giải trình trong các hệ thống yêu cầu minh bạch. Ngoài ra, tuning LSTM (tối ưu tham số như số cell, số tầng, dropout, learning rate) khá phức tạp, dễ dẫn đến overfitting nếu không có kỹ thuật regularization phù hợp.


#### **Ứng dụng của LSTM trong bài toán dự đoán thời gian còn lại của pin Li-on:**

- Mô hình LSTM được sử dụng như một phương pháp học sâu nhằm khai thác tính chất chuỗi thời gian của dữ liệu RUL theo chu kỳ vận hành của pin. LSTM có cấu trúc gồm các cổng nhớ, cho phép mô hình ghi nhớ thông tin dài hạn và học được xu hướng suy giảm của pin theo thời gian. Dữ liệu sau tiền xử lý được đưa vào mô hình dưới dạng chuỗi có độ dài cố định để LSTM học các mẫu thay đổi của đặc trưng theo từng bước thời gian. Mặc dù phù hợp về mặt lý thuyết, mô hình LSTM gặp hạn chế do dữ liệu gốc mang tính bất đồng nhất hơn chuỗi thời gian thuần túy. Sau quá trình huấn luyện, LSTM được đánh giá trên tập test và kết quả cho thấy hiệu suất thấp

hơn các mô hình học máy truyền thống, phản ánh sự không tương thích hoàn toàn của kiến trúc LSTM với dạng dữ liệu sử dụng trong dự án.

#### 4.2.2 Mô hình *Gated Recurrent Unit (GRU)*

Cơ sở lý thuyết: **GRU (Gated Recurrent Unit)** là một kiến trúc mạng nơ-ron hồi tiếp (RNN) được phát triển như một biến thể rút gọn và tối ưu hơn của mô hình LSTM. GRU sử dụng hai cổng chính – cổng cập nhật (update gate) và cổng reset (reset gate) – để điều khiển dòng chảy thông tin trong mạng mà không cần đến bộ nhớ cell phức tạp như LSTM. Nhờ thiết kế đơn giản hơn nhưng vẫn duy trì được khả năng nắm bắt các quan hệ phụ thuộc dài hạn trong dữ liệu tuần tự, GRU trở thành lựa chọn hiệu quả trong các bài toán xử lý ngôn ngữ tự nhiên, phân tích chuỗi thời gian và các ứng dụng liên quan đến mô hình hóa tín hiệu. Với tốc độ huấn luyện nhanh hơn và mức tiêu thụ tài nguyên thấp hơn, GRU thường được sử dụng khi cần cân bằng giữa hiệu năng và chi phí tính toán.



Hình 4.5 GRU là gì

#### Ưu điểm của GRU:

- GRU có kiến trúc đơn giản và gọn nhẹ hơn LSTM, nhờ việc giảm số lượng cổng từ ba xuống hai và không sử dụng thêm cell state riêng biệt. Điều này

giúp giảm số tham số và giảm độ phức tạp tính toán, dẫn đến **tốc độ** huấn luyện và suy luận nhanh hơn, phù hợp cho các mô hình chạy trên thiết bị giới hạn tài nguyên hoặc yêu cầu xử lý thời gian thực.

- GRU thường dễ tối ưu hơn so với LSTM do có ít siêu tham số hơn. Việc điều chỉnh mô hình trở nên đơn giản hơn, giảm nguy cơ overfitting và giúp mô hình hội tụ nhanh hơn trong quá trình huấn luyện. Điều này đặc biệt hữu ích trong các dự án yêu cầu thử nghiệm nhiều mô hình hoặc yêu cầu vòng lặp huấn luyện nhanh.

#### **Nhược điểm của GRU:**

- Mặc dù gọn nhẹ, GRU đôi khi kém linh hoạt hơn so với LSTM trong các chuỗi dài và phức tạp. Kiến trúc đơn giản hơn cũng đồng nghĩa với việc khả năng kiểm soát dòng thông tin của GRU không tinh vi bằng LSTM, dẫn đến việc mô hình có thể không học được đầy đủ các phụ thuộc dài hạn trong một số tác vụ chuyên sâu.
- GRU ít phổ biến hơn LSTM trong một số lĩnh vực truyền thống, do LSTM đã được nghiên cứu và kiểm chứng rộng rãi hơn trong cộng đồng khoa học. Điều này có thể dẫn đến ít tài liệu tối ưu hóa hoặc hướng dẫn chuyên sâu hơn khi sử dụng GRU trong các bài toán phức tạp, đặc biệt là khi cần thiết kế các kiến trúc deep learning nhiều tầng.

#### **Ứng dụng của GRU trong bài toán dự đoán thời gian hoạt động còn lại của pin Li-on:**


- GRU được sử dụng với mục tiêu khai thác thông tin theo chuỗi thời gian từ dữ liệu RUL, tương tự như LSTM nhưng với cấu trúc gọn nhẹ hơn nhờ sử dụng hai cổng cập nhật và reset. GRU được kỳ vọng có thể học tốt xu hướng suy giảm của pin dựa trên các đặc trưng ở từng chu kỳ vận hành. Sau khi dữ liệu được xử lý và chuyển về dạng chuỗi đầu vào, mô hình được huấn luyện trên tập train để nhận diện quan hệ biến đổi theo chu kỳ. Tuy nhiên, do bản chất dữ liệu thiên về dạng bảng (tabular) hơn là chuỗi thời gian liên tục, GRU không học được pattern phù hợp, dẫn đến sai số dự



đoán rất lớn. Kết quả trên tập test cho thấy hiệu suất của GRU thấp và không phù hợp với cấu trúc dữ liệu trong bài toán này.

#### 4.2.3 Mô hình *Convolutional Neural Network*

Cơ sở lý thuyết: là một kiến trúc mạng nơ-ron chuyên biệt được thiết kế để xử lý dữ liệu có cấu trúc không gian, đặc biệt là hình ảnh và tín hiệu. Khác với các mô hình fully-connected truyền thống, CNN khai thác phép tích chập (convolution) để trích xuất các đặc trưng cục bộ từ dữ liệu đầu vào thông qua các bộ lọc (filters) có khả năng học. Nhờ cơ chế này, CNN có thể tự động học các đặc trưng từ đơn giản đến phức tạp như cạnh, họa tiết, hình dạng hoặc các cấu trúc ngữ nghĩa. Mô hình này cũng đạt hiệu quả cao trong NLP khi áp dụng cho phân loại văn bản hoặc trích xuất đặc trưng câu. Với khả năng học đặc trưng mạnh mẽ và hiệu suất xử lý nhanh, CNN trở thành nền tảng quan trọng trong deep learning, đặc biệt trong thị giác máy tính và các tác vụ có tính cục bộ.



Hình 4.6 CNN là gì

**Ưu điểm của CNN:**

- CNN có khả năng tự động học đặc trưng từ dữ liệu mà không cần thiết kế thủ công. Các tầng tích chập giúp mô hình học được những mẫu cục bộ hữu ích trong dữ liệu, từ đơn giản (điểm, cạnh) đến phức tạp (đối tượng hoặc cấu trúc ngữ nghĩa), giúp CNN vượt trội hơn các mô hình truyền thống trong các nhiệm vụ thị giác máy tính và các bài toán xử lý tín hiệu.
- CNN giảm đáng kể số lượng tham số nhờ phép tích chập và cơ chế chia sẻ trọng số. Thay vì kết nối mọi neuron như mạng fully-connected, mỗi filter trong CNN chỉ hoạt động trên một vùng nhỏ của dữ liệu, giúp giảm độ phức tạp tính toán và hạn chế overfitting. Điều này khiến CNN vừa hiệu quả, vừa dễ mở rộng sang mô hình sâu hơn mà không làm tăng chi phí quá mức.

#### **Nhược điểm của CNN:**

- CNN có thể không phù hợp với dữ liệu không mang tính cục bộ hoặc không có cấu trúc không gian rõ ràng, như quan hệ dài hạn trong ngôn ngữ tự nhiên. Mặc dù CNN được ứng dụng thành công trong NLP qua các lớp 1D-convolution, nhưng khả năng mô hình hóa quan hệ dài hạn vẫn hạn chế so với các mô hình tuần tự như LSTM hoặc các mô hình attention hiện đại như Transformer.
- CNN yêu cầu khối lượng dữ liệu huấn luyện lớn để đạt hiệu quả tối đa. Với các bài toán thị giác máy tính hoặc tín hiệu phức tạp, việc huấn luyện từ đầu một mô hình CNN đòi hỏi tập dữ liệu quy mô lớn và đa dạng, gây khó khăn cho những dự án có dữ liệu hạn chế. Khi dữ liệu ít, CNN dễ bị overfitting nếu không áp dụng các kỹ thuật regularization.

#### **Ứng dụng của CNN trong bài toán dự đoán thời gian hoạt động còn lại của pin Li-on:**

- Trong dự án, mô hình CNN được áp dụng với mục tiêu khai thác các đặc trưng theo chuỗi từ dữ liệu RUL thông qua các bộ lọc tích chập một chiều. CNN có khả năng nhận diện các pattern lặp lại hoặc cấu trúc cục bộ trong chuỗi dữ liệu, nên được kỳ vọng sẽ phát hiện được các tín hiệu suy giảm

của pin theo từng chu kỳ. Sau khi dữ liệu được chuyển về dạng chuỗi thời gian, mô hình được huấn luyện bằng các lớp tích chập và pooling nhằm rút trích đặc trưng rồi đưa qua lớp dự đoán. Tuy nhiên, do dữ liệu RUL trong dự án mang tính bảng nhiều hơn là chuỗi thời gian liên tục, các pattern mà CNN cần lại không thể hình thành rõ ràng. Kết quả trên tập test cho thấy mô hình CNN không đạt hiệu suất cao, phản ánh sự không tương thích giữa cấu trúc CNN và dạng dữ liệu sử dụng.

## CHƯƠNG 5. THỰC NGHIỆM VÀ SO SÁNH KẾT QUẢ

### 5.1 Thực nghiệm

#### 5.1.1 Các thư viện được sử dụng

Import các thư viện cần thiết để huấn luyện các mô hình cho bài toán dự đoán thời gian hoạt động còn lại của pin Li-on.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

print("Thư viện đã import thành công!")
```

Thư viện đã import thành công!

Hình 5.1 Import thư viện sử dụng

Các thư viện được sử dụng bao gồm:

- Pandas: đọc, quản lý thao tác dữ liệu, cung cấp các quan trọng như xử lý giá trị thiếu, thống kê mô tả, lọc và chuyển đổi dữ liệu.
- Numpy: dùng để xử lý tính toán số học hiệu quả và làm việc với mảng dữ liệu đa chiều.
- Matplotlib: dùng để vẽ các biểu đồ.
- Seaborn: vẽ các biểu đồ và ma trận.
- Scikit-learn: thư viện chính cho các mô hình học máy

#### 5.1.2 Đọc dữ liệu đã tiền xử lý và *Feature engineering*

Dữ liệu sau khi đã được tiền xử lý tiến hành đọc lên lại kiểm tra kích thước và các cột của dữ liệu.

```
# Load dữ liệu đã tiền xử lý
file_path = r"data/processed/Battery_RUL_processed.csv"
df = pd.read_csv(file_path)
print("Kích thước dữ liệu:", df.shape)
print("Các cột dữ liệu:", list(df.columns))
df.describe()
```

Python

Kích thước dữ liệu: (15064, 9)

Các cột dữ liệu: ['Cycle\_Index', 'Discharge Time (s)', 'Decrement 3.6–3.4V (s)', 'Max. Voltage Dischar. (V)', 'Min. Voltage Charg. (V)', 'Time at 4.15V (s)', 'Time constant current

|       | Cycle_Index   | Discharge Time (s) | Decrement 3.6–3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | RUL          |
|-------|---------------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|--------------|
| count | 1.506400e+04  | 1.506400e+04       | 1.506400e+04           | 1.506400e+04              | 1.506400e+04            | 1.506400e+04      | 1.506400e+04              | 1.506400e+04      | 15064.000000 |
| mean  | -7.546922e-17 | 2.339546e-16       | 1.245242e-16           | 6.037538e-15              | -1.467876e-15           | 6.414884e-17      | -2.264077e-17             | 1.205621e-15      | 554.194172   |
| std   | 1.000033e+00  | 1.000033e+00       | 1.000033e+00           | 1.000033e+00              | 1.000033e+00            | 1.000033e+00      | 1.000033e+00              | 1.000033e+00      | 322.434514   |
| min   | -1.722117e+00 | -3.294855e+00      | -3.053233e+00          | -3.121090e+00             | -2.904493e+00           | -2.354259e+00     | -2.626440e+00             | -2.831466e+00     | 0.000000     |
| 25%   | -8.845642e-01 | -8.640544e-01      | -8.152215e-01          | -7.692902e-01             | -7.387392e-01           | -8.917218e-01     | -8.809080e-01             | -7.205829e-01     | 277.000000   |
| 50%   | 1.192735e-02  | -1.299403e-02      | -1.786203e-01          | -2.268704e-02             | -2.919685e-02           | -6.250830e-02     | -2.125204e-02             | 1.025103e-02      | 551.000000   |
| 75%   | 8.587862e-01  | 7.564792e-01       | 6.767859e-01           | 7.985765e-01              | 7.050970e-01            | 8.094742e-01      | 7.893742e-01              | 6.866725e-01      | 839.000000   |
| max   | 1.792502e+00  | 3.187280e+00       | 2.914797e+00           | 3.150377e+00              | 2.870851e+00            | 3.361268e+00      | 3.294798e+00              | 2.797556e+00      | 1133.000000  |

Hình 5.2 Kích thước dữ liệu

Bộ dữ liệu có tổng cộng 9 cột và 15064 hàng dữ liệu.

Bên cạnh các đặc trưng gốc, thực hiện bước feature engineering nhằm tăng khả năng mô hình học được xu hướng suy giảm của pin theo chu kỳ, đặc biệt trong bối cảnh rằng các đại lượng đo có thể nhiễu hoặc biến thiên không tuyến tính. Chia ra làm 2 nhóm đặc trưng như sau:

- Nhóm đặc trưng mang ý nghĩa vật lý (Physical-inspired features):
  - + Efficiency Ratio (Tỷ lệ hiệu suất): được tính bằng tỷ lệ giữa *thời gian xả* và *thời gian sạc*. Trên thực tế, khi pin lão hoá, hiệu suất sạc–xả có thể thay đổi, vì vậy đặc trưng này giúp mô hình nhận biết tình trạng suy giảm dựa trên mối tương quan giữa hai quá trình sạc và xả.
  - + Voltage Drop Rate (Tốc độ sụt áp trung bình): được tính từ biên độ chênh lệch điện áp giữa mức cao nhất khi xả và mức thấp nhất khi sạc, sau đó chia cho thời gian xả. Đây là đặc trưng thể hiện mức “tụt áp” theo thời gian, thường liên quan đến nội trở và mức độ suy giảm của pin.
- Nhóm đặc trưng theo chuỗi thời gian (Time-series features):
  - + Discharge Drop Rate: sử dụng phép sai phân (diff) của thời gian xả theo chu kỳ để mô tả tốc độ thay đổi dung lượng/tình trạng xả giữa chu kỳ hiện tại so với chu kỳ trước.
  - + Rolling Mean (cửa sổ 10 chu kỳ): lấy trung bình trượt của thời gian xả trong 10 chu kỳ gần nhất nhằm làm mượt nhiễu cục bộ và làm rõ xu hướng suy giảm theo thời gian.

+ Rolling Std (cửa sổ 10 chu kỳ): đo độ dao động của thời gian xả trong một khoảng chu kỳ giá trị lớn thể hiện hoạt động không ổn định, có thể là dấu hiệu của pin đang suy giảm.

+ Lag Feature (Prev Cycle Discharge): lấy giá trị thời gian xả của chu kỳ trước bổ sung thông tin quá khứ gần để mô hình dự đoán tốt hơn (đặc biệt phù hợp với các mô hình xử lý chuỗi).

Kích thước sau Feature Engineering: (15064, 15)

Thống kê dữ liệu mới:

|       | Cycle_Index  | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) |
|-------|--------------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|
| count | 15064.000000 | 15064.000000       | 15064.000000           | 15064.000000              | 15064.000000            | 15064.000000      | 15064.000000              | 15064.000000      |
| mean  | 556.155005   | 2431.494567        | 522.232835             | 3.908176                  | 3.577904                | 3215.651277       | 4146.187166               | 8641.906719       |
| std   | 322.378480   | 11948.500108       | 1436.811036            | 0.091003                  | 0.123695                | 3675.177157       | 4755.914947               | 4476.833081       |
| min   | 1.000000     | 34.380000          | 38.709677              | 3.043000                  | 3.022000                | 255.241143        | 8.000000                  | 8.380000          |
| 25%   | 271.000000   | 1168.717500        | 320.000000             | 3.846000                  | 3.488000                | 1834.027286       | 2564.310000               | 7837.535000       |
| 50%   | 560.000000   | 1555.380000        | 438.857143             | 3.906000                  | 3.574000                | 2924.359000       | 3788.380000               | 8313.235000       |
| 75%   | 833.000000   | 1906.675000        | 598.400000             | 3.972000                  | 3.663000                | 4076.344000       | 5012.320000               | 8756.360000       |
| max   | 1134.000000  | 197940.480000      | 86584.925500           | 4.363000                  | 4.379000                | 62910.013000      | 78270.020000              | 78660.000000      |

Hình 5.3 Dữ liệu sau khi xử lý Feature

Sau khi xử lý feature engineering xong tiến hành kiểm tra tính hợp lệ và xử lý dữ liệu lỗi sau khi thực hiện quá trình này.

Do một số đặc trưng mới được tạo ra từ phép chia và phép sai phân, có thể xuất hiện các giá trị âm hoặc không hợp lý.

```
# Kiểm tra các cột có giá trị âm
neg_cols = [col for col in df.columns if (df[col] < 0).any()]
print("Các cột có chứa số âm:", neg_cols)
```

Các cột có chứa số âm: ['Voltage\_Drop\_Rate', 'Discharge\_Drop\_Rate']

```
error_mask = df['Voltage_Drop_Rate'] < 0
print(f"Phát hiện {error_mask.sum()} dòng dữ liệu lỗi điện áp (Voltage Drop Rate < 0).")

# Loại bỏ các dòng dữ liệu lỗi
df = df[~error_mask].copy()
neg_cols_final = [col for col in df.columns if (df[col] < 0).any()]
print("Các cột còn số âm:", neg_cols_final)
```

Phát hiện 415 dòng dữ liệu lỗi điện áp (Voltage Drop Rate < 0).  
Các cột còn số âm: ['Discharge\_Drop\_Rate']

Hình 5.4 Xử lý dữ liệu lỗi sau Feature

### 5.1.3 Chia dữ liệu và chuẩn hóa

Dữ liệu đã được xử lý tiến hành chia thành 2 tập dữ liệu là tập huấn luyện (train) và kiểm tra (test) theo tỷ lệ 80/20 và chuẩn hóa dữ liệu bằng kỹ thuật StandardScaler để đưa các features về cùng thang đo (scale) theo phân phối chuẩn hóa (mean của feature  $\approx 0$  và std của feature  $\approx 1$ ).

Chia dữ liệu thành tập huấn luyện (train) và kiểm tra (test) theo tỷ lệ 80/20. Chuẩn hóa bằng StandardScaler

```
# Tách dữ liệu
X = df.drop(columns=['RUL'])
y = df['RUL']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
scaler.fit(X_train)

X_train = scaler.transform(X_train)
X_test = scaler.transform(X_test)

print(f"Train: {X_train.shape}, Test: {X_test.shape}")
```

Train: (11719, 14), Test: (2930, 14)

Hình 5.5 Chia dữ liệu huấn luyện

### 5.1.4 Huấn luyện mô hình *Machine learning*

Huấn luyện với mô hình học máy truyền thống Linear Regression và Random Forest, được xây dựng và huấn luyện để dự đoán tuổi thọ của pin (RUL) dựa trên 8 đặc trưng đầu vào, sau đó sử dụng tập kiểm tra để đánh giá mô hình bằng các chỉ số RMSE, MAE và  $R^2$ .

Huấn luyện mô hình Linear Regression

```
# Linear Regression
lr = LinearRegression()
lr.fit(X_train, y_train)

# Đánh giá Linear Regression
y_pred_lr = lr.predict(X_test)
rmse_lr = np.sqrt(mean_squared_error(y_test, y_pred_lr))
mae_lr = mean_absolute_error(y_test, y_pred_lr)
r2_lr = r2_score(y_test, y_pred_lr)
print("Linear Regression:")
print(f"RMSE: {rmse_lr:.4f}")
print(f"MAE: {mae_lr:.4f}")
print(f"R2: {r2_lr:.4f}")
```

```
Linear Regression:
RMSE: 7.0582
MAE: 4.4195
R2: 0.9995
```

Hình 5.6 Huấn luyện mô hình Linear Regression

Kết quả cho thấy mô hình đã khớp khá tốt với dữ liệu tuy nhiên vì bản chất tuyến tính nên mô hình vẫn bị hạn chế trong việc học được các quan hệ phi tuyến tính của dữ liệu.

Huấn luyện mô hình Random Forest



```

# Random Forest
rf = RandomForestRegressor(n_estimators=200, random_state=42)
rf.fit(X_train, y_train)

# Đánh giá Random Forest
y_pred_rf = rf.predict(X_test)
rmse_rf = np.sqrt(mean_squared_error(y_test, y_pred_rf))
mae_rf = mean_absolute_error(y_test, y_pred_rf)
r2_rf = r2_score(y_test, y_pred_rf)
print("Random Forest:")
print(f"RMSE: {rmse_rf:.4f}")
print(f"MAE: {mae_rf:.4f}")
print(f"R2: {r2_rf:.4f}")

```

```

Random Forest:
RMSE: 4.4258
MAE: 2.5785
R2: 0.9998

```

Hình 5.7 Huấn luyện mô hình Random Forest

Kết quả của mô hình đạt hiệu suất cao hơn Linear Regression nhờ khả năng mô hình hóa tốt các quan hệ phi tuyến tính và giảm thiểu overfitting nhờ cơ chế bagging.

### 5.1.5 Huấn luyện mô hình Deep Learning

Để huấn luyện cho các mô hình deep không thể dùng dữ liệu dạng bảng thông thường, vì vậy cần phải chuyển đổi dữ liệu thô thành các chuỗi (sequences) có độ dài cố định để mô hình có thể học được quan hệ theo thời gian. Sau đó tách dữ liệu thành tập huấn luyện và kiểm tra theo dạng chuỗi.

```
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Input, GRU, Dense, Dropout, Conv1D, MaxPooling1D, Flatten
from tensorflow.keras.optimizers import Adam

# Early stopping callback
early_stopping = tf.keras.callbacks.EarlyStopping(monitor='val_loss', patience=10, restore_best_weights=True)

# Chuẩn bị dữ liệu cho mô hình chuỗi thời gian
def create_sequences(X, y, seq_len=50):
    X = np.array(X)
    y = np.array(y)

    Xs, ys = [], []
    for i in range(len(X) - seq_len + 1):
        Xs.append(X[i:i+seq_len])
        ys.append(y[i+seq_len-1])
    return np.array(Xs), np.array(ys)
```

✓ 0.0s

```
sequence_length = 50

X_train_seq, y_train_seq = create_sequences(X_train, y_train, sequence_length)
X_test_seq, y_test_seq = create_sequences(X_test, y_test, sequence_length)
print(f"Train seq shape: {X_train_seq.shape}, Test seq shape: {X_test_seq.shape}")
```

✓ 0.0s

Train seq shape: (12002, 50, 8), Test seq shape: (2964, 50, 8)

Hình 5.8 Chuyển đổi dữ liệu chuỗi

Xây dựng hàm đánh giá so sánh hiệu suất giữa các mô hình chuẩn bị huấn luyện.

```
# Hàm đánh giá model
def evaluate_model(model, X_test, y_test, name="Model"):
    y_pred = model.predict(X_test)
    # Nếu dự đoán ra 2D thì flatten
    if len(y_pred.shape) > 1:
        y_pred = y_pred.flatten()

    rmse = np.sqrt(mean_squared_error(y_test, y_pred))
    mae = mean_absolute_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)
    print(f"{name}:")
    print(f"  RMSE: {rmse:.4f}")
    print(f"  MAE : {mae:.4f}")
    print(f"  R2  : {r2:.4f}")
    return rmse, mae, r2
```

✓ 0.0s

Hình 5.9 Hàm đánh giá mô hình

## Huấn luyện mô hình LSTM

```
# LSTM model
lstm_model = Sequential([
    Input(shape=(X_train_seq.shape[1], X_train_seq.shape[2])),
    LSTM(128, return_sequences=True),
    Dropout(0.2),
    LSTM(64),
    Dropout(0.2),
    Dense(16, activation='relu'),
    Dense(1)
])
print('Huấn luyện LSTM...')
lstm_model.compile(optimizer=Adam(0.001), loss='mse', metrics=['mae'])
lstm_model.fit(X_train_seq, y_train_seq, epochs=50, batch_size=32, validation_split=0.2, callbacks=[early_stopping])

rmse_lstm, mae_lstm, r2_lstm = evaluate_model(lstm_model, X_test_seq, y_test_seq, name="LSTM")
```

```
Huấn luyện LSTM...
Epoch 1/50
292/292 ————— 10s 26ms/step - loss: 385603.1875 - mae: 531.0103 - val_loss: 288980.5938 - val_mae: 446.2755
Epoch 2/50
292/292 ————— 7s 25ms/step - loss: 252253.3438 - mae: 411.8808 - val_loss: 150506.6250 - val_mae: 322.2596
Epoch 3/50
292/292 ————— 7s 25ms/step - loss: 133167.2812 - mae: 305.8168 - val_loss: 107106.9688 - val_mae: 282.0593
Epoch 4/50
292/292 ————— 7s 24ms/step - loss: 106608.9609 - mae: 281.9856 - val_loss: 103830.9297 - val_mae: 278.5976
Epoch 5/50
292/292 ————— 7s 23ms/step - loss: 104369.8672 - mae: 278.3146 - val_loss: 103816.8281 - val_mae: 278.5770
Epoch 6/50
292/292 ————— 7s 24ms/step - loss: 105602.1953 - mae: 280.9443 - val_loss: 103795.1875 - val_mae: 278.5440
Epoch 7/50
292/292 ————— 8s 28ms/step - loss: 104618.6172 - mae: 279.5442 - val_loss: 103823.4688 - val_mae: 278.5869
Epoch 8/50
292/292 ————— 9s 30ms/step - loss: 104816.9062 - mae: 280.3398 - val_loss: 103800.6953 - val_mae: 278.5529
Epoch 9/50
292/292 ————— 9s 29ms/step - loss: 94037.9141 - mae: 258.1354 - val_loss: 19268.8809 - val_mae: 96.4220
Epoch 10/50
292/292 ————— 7s 25ms/step - loss: 15749.7891 - mae: 83.1920 - val_loss: 4595.1362 - val_mae: 40.1182
Epoch 11/50
292/292 ————— 7s 25ms/step - loss: 5665.5571 - mae: 51.5271 - val_loss: 1688.1217 - val_mae: 26.6049
Epoch 12/50
292/292 ————— 7s 24ms/step - loss: 3459.1575 - mae: 43.4955 - val_loss: 886.1412 - val_mae: 18.5892
...
LSTM:
RMSE: 20.0067
MAE : 14.2449
R2 : 0.9961
```

Hình 5.10 Huấn luyện mô hình LSTM

Kết quả cho thấy mô hình LSTM có khả năng giải thích gần như toàn bộ biến thiên của dữ liệu đầu ra.

Huấn luyện mô hình GRU

```
# GRU model
gru_model = Sequential([
    Input(shape=(X_train_seq.shape[1], X_train_seq.shape[2])),
    GRU(128, return_sequences=True),
    Dropout(0.2),
    GRU(64),
    Dropout(0.2),
    Dense(16, activation='relu'),
    Dense(1)
])
print('Huấn luyện GRU...')
gru_model.compile(optimizer=Adam(0.001), loss='mse', metrics=['mae'])
gru_model.fit(X_train_seq, y_train_seq, epochs=50, batch_size=32, validation_split=0.2, callbacks=[early_stopping])

rmse_gru, mae_gru, r2_gru = evaluate_model(gru_model, X_test_seq, y_test_seq, name="GRU")
```

Huấn luyện GRU...

Epoch 1/50  
**292/292** ————— 12s 33ms/step - loss: 386463.1562 - mae: 532.9796 - val\_loss: 256654.5000 - val\_mae: 417.5420

Epoch 2/50  
**292/292** ————— 9s 31ms/step - loss: 211046.3125 - mae: 376.0804 - val\_loss: 121859.4375 - val\_mae: 296.3525

Epoch 3/50  
**292/292** ————— 9s 31ms/step - loss: 111936.3984 - mae: 284.8914 - val\_loss: 104215.7266 - val\_mae: 279.0539

Epoch 4/50  
**292/292** ————— 9s 31ms/step - loss: 104293.5312 - mae: 278.3243 - val\_loss: 103803.7812 - val\_mae: 278.5575

Epoch 5/50  
**292/292** ————— 9s 31ms/step - loss: 107785.8828 - mae: 285.2434 - val\_loss: 103889.0859 - val\_mae: 278.6745

Epoch 6/50  
**292/292** ————— 9s 31ms/step - loss: 100133.9531 - mae: 269.7486 - val\_loss: 22467.3828 - val\_mae: 97.5358

Epoch 7/50  
**292/292** ————— 9s 31ms/step - loss: 16830.7285 - mae: 89.7854 - val\_loss: 4576.0234 - val\_mae: 38.9928

Epoch 8/50  
**292/292** ————— 9s 31ms/step - loss: 6622.6045 - mae: 60.0540 - val\_loss: 1842.2472 - val\_mae: 29.3641

Epoch 9/50  
**292/292** ————— 9s 32ms/step - loss: 5117.8638 - mae: 55.6082 - val\_loss: 1354.9240 - val\_mae: 23.5909

Epoch 10/50  
**292/292** ————— 9s 32ms/step - loss: 4542.2578 - mae: 52.9121 - val\_loss: 794.7416 - val\_mae: 17.4377

Epoch 11/50  
**292/292** ————— 9s 31ms/step - loss: 4266.1377 - mae: 51.4234 - val\_loss: 837.9750 - val\_mae: 20.0086

Epoch 12/50  
**292/292** ————— 9s 31ms/step - loss: 4100.7383 - mae: 50.3738 - val\_loss: 695.1169 - val\_mae: 18.3841

...

GRU:  
 RMSE: 13.1606  
 MAE : 8.8896  
 R2 : 0.9983

Hình 5.11 Huấn luyện mô hình GRU

Kết quả huấn luyện mô hình GRU cho thấy trong cấu hình hiện tại chưa phù hợp với dữ liệu chuỗi đang sử dụng và có xu hướng overfitting mạnh.

Huấn luyện mô hình CNN

```
# CNN model
cnn_model = Sequential([
    Input(shape=(X_train_seq.shape[1], X_train_seq.shape[2])),
    Conv1D(64, kernel_size=3, activation='relu'),
    MaxPooling1D(pool_size=2),
    Conv1D(32, kernel_size=3, activation='relu'),
    MaxPooling1D(pool_size=2),
    Flatten(),
    Dense(16, activation='relu'),
    Dense(1)
])
print('Huấn luyện CNN...')
cnn_model.compile(optimizer=Adam(0.001), loss='mse', metrics=['mae'])
cnn_model.fit(X_train_seq, y_train_seq, epochs=50, batch_size=32, validation_split=0.2, callbacks=[early_stopping])

rmse_cnn, mae_cnn, r2_cnn = evaluate_model(cnn_model, X_test_seq, y_test_seq, name="CNN")
```

Huấn luyện CNN...

Epoch 1/50  
 292/292 ————— 2s 3ms/step - loss: 233249.5781 - mae: 395.6665 - val\_loss: 105912.2188 - val\_mae: 280.1944

Epoch 2/50  
 292/292 ————— 1s 3ms/step - loss: 105907.1953 - mae: 280.4508 - val\_loss: 104059.2109 - val\_mae: 278.3478

Epoch 3/50  
 292/292 ————— 1s 3ms/step - loss: 102261.7422 - mae: 275.2662 - val\_loss: 100643.6328 - val\_mae: 273.9231

Epoch 4/50  
 292/292 ————— 1s 4ms/step - loss: 97519.6562 - mae: 269.1052 - val\_loss: 84365.6484 - val\_mae: 249.8157

Epoch 5/50  
 292/292 ————— 1s 4ms/step - loss: 76047.1328 - mae: 234.5058 - val\_loss: 53547.6289 - val\_mae: 190.4350

Epoch 6/50  
 292/292 ————— 1s 3ms/step - loss: 46059.8750 - mae: 174.8552 - val\_loss: 38999.7344 - val\_mae: 156.4977

Epoch 7/50  
 292/292 ————— 1s 3ms/step - loss: 32563.2695 - mae: 144.3538 - val\_loss: 30628.8301 - val\_mae: 140.6250

Epoch 8/50  
 292/292 ————— 1s 3ms/step - loss: 26281.9883 - mae: 128.6732 - val\_loss: 24904.8457 - val\_mae: 124.1843

Epoch 9/50  
 292/292 ————— 1s 3ms/step - loss: 22291.1035 - mae: 118.4835 - val\_loss: 22117.7539 - val\_mae: 117.7498

Epoch 10/50  
 292/292 ————— 1s 3ms/step - loss: 19937.1992 - mae: 111.7625 - val\_loss: 19842.9395 - val\_mae: 111.0533

Epoch 11/50  
 292/292 ————— 1s 3ms/step - loss: 18072.4766 - mae: 105.5234 - val\_loss: 17854.2305 - val\_mae: 105.0325

Epoch 12/50  
 292/292 ————— 1s 3ms/step - loss: 16610.0156 - mae: 101.3886 - val\_loss: 16716.9297 - val\_mae: 101.0105

...

CNN:  
 RMSE: 73.2822  
 MAE : 55.3831  
 R2 : 0.9472

Hình 5.12 Huấn luyện mô hình CNN

Kết quả huấn luyện mô hình cho thấy tốt hơn mô hình GRU vượt trội hơn hoàn toàn và đứng sau LSTM

### 5.1.6 Huấn luyện mô hình tối ưu XGBoost

Thay vì sử dụng bộ tham số mặc định, mô hình được cấu hình với các siêu tham số đã được tối ưu hóa trước bằng thuật toán tìm kiếm siêu tham số.

Huấn luyện mô hình XGBoost với các tham số đã được tối ưu hóa bằng thuật toán tìm kiếm siêu tham số.

Nguồn: <https://www.kaggle.com/code/exceededdose/best-rul-prediction-model>

```
from xgboost import XGBRegressor

best_params = {
    'n_estimators': 236,
    'max_depth': 10,
    'learning_rate': 0.03303851203638283,
    'subsample': 0.6594050174570553,
    'colsample_bytree': 0.9712398646893982,
    'gamma': 2.6569769714190774,
    'reg_alpha': 1.2599527471696812,
    'reg_lambda': 3.351172640816224
}

best_model = XGBRegressor(**best_params, random_state=42, objective='reg:squarederror')
best_model.fit(X_train, y_train)

rmse_xgb, mae_xgb, r2_xgb = evaluate_model(best_model, X_test, y_test, name="XGBoost")
```

```
XGBoost:
RMSE: 3.3522
MAE : 2.1074
R2  : 0.9999
```

Hình 5.13 Huấn luyện mô hình XGBoost

Kết quả cho thấy mô hình XGBoost đạt hiệu năng rất cao trên tập kiểm tra.

## 5.2 So sánh kết quả

So sánh kết quả các mô hình dựa vào các chỉ số RMSE, MAE,  $R^2$ .

So sánh các mô hình dựa trên các chỉ số RMSE, MAE, R2 để chọn ra mô hình tốt nhất.

```
results = {}
results['Linear Regression'] = (rmse_lr, mae_lr, r2_lr)
results['Random Forest'] = (rmse_rf, mae_rf, r2_rf)
results['LSTM'] = (rmse_lstm, mae_lstm, r2_lstm)
results['GRU'] = (rmse_gru, mae_gru, r2_gru)
results['CNN'] = (rmse_cnn, mae_cnn, r2_cnn)
results['XGBoost'] = (rmse_xgb, mae_xgb, r2_xgb)
results_df = pd.DataFrame(results, index=['RMSE', 'MAE', 'R2']).T
print(results_df)
```

|                   | RMSE      | MAE       | R2       |
|-------------------|-----------|-----------|----------|
| Linear Regression | 7.058184  | 4.419537  | 0.999510 |
| Random Forest     | 4.425758  | 2.578514  | 0.999807 |
| LSTM              | 20.006677 | 14.244881 | 0.996063 |
| GRU               | 13.160570 | 8.889558  | 0.998296 |
| CNN               | 73.282199 | 55.383066 | 0.947174 |
| XGBoost           | 3.352168  | 2.107352  | 0.999889 |


Hình 5.14 So sánh kết quả các mô hình

Kết quả cho thấy mô hình XGBoost và Random Forest vượt trội hơn so với các mô hình còn lại.

### 5.3 Dự đoán và đánh giá

Trước hết là các biểu đồ so sánh về hiệu năng của các mô hình được sử dụng.


Nhóm biểu đồ Actual vs Predicted



Hình 5.15 Biểu đồ giá trị thực và giá trị đoán

Qua các biểu đồ cho thấy với các mô hình XGBoost, Random Forest, Linear Regression: các điểm gần như dính vào đường chéo nghĩa là mô hình dự đoán số chu kỳ còn lại của pin rất sát với thực tế.

#### Nhóm biểu đồ phân bố lỗi (Residuals Distribution)




Hình 5.16 Biểu đồ phân bố lỗi

Các mô hình XGBoost, Random Forest và Linear Regression cho thấy phân bố tập trung quanh 0 nghĩa là phần lớn pin được dự đoán RUL lệch rất ít so với thực tế còn các mô hình còn lại với dải residual rộng hơn sẽ gây ra dự đoán lệch nhiều hơn.

#### Nhóm biểu đồ Time Series Comparison






Hình 5.17 Biểu đồ so sánh theo chu kỳ thời gian

Đối với biểu đồ này nếu hai đường gần như chồng lên nhau thì mô hình sẽ theo sát quá trình suy giảm của pin không chỉ đúng về tổng thể mà còn đúng từng đoạn.

Nhóm biểu đồ các chỉ số RMSE, MAE,  $R^2$




Hình 5.18 Biểu đồ so sánh RMSE, MAE,  $R^2$

Đứng đầu sẽ là mô hình XGBoost sau đó là tới Random Forest là tốt nhất. Linear Regression cũng ổn, còn nhóm LSTM, CNN chỉ đạt trung bình, còn mô hình GRU rất tệ trong bài toán này.

Dự đoán thử:

Với 3 mô hình cho kết quả tốt nhất là XGBoost, Random Forest, Linear Regression sẽ được dự đoán thử kết quả RUL với 10 mẫu ngẫu nhiên.



Hình 5.19 Dự đoán kết quả

Biểu đồ cho biết với từng mẫu cụ thể, mỗi mô hình lệch bao nhiêu so với thực tế.

---

DỰ ĐOÁN THỬ VỚI CÁC MÔ HÌNH TỐT NHẤT

---

Dự đoán cho 3000 mẫu ngẫu nhiên:

---

|             | Actual_RUL | XGBoost     | Random_Forest | Linear_Regression \ |
|-------------|------------|-------------|---------------|---------------------|
| Sample_1    | 463        | 462.850006  | 467.56        | 468.48              |
| Sample_2    | 919        | 917.530029  | 919.48        | 921.45              |
| Sample_3    | 33         | 33.020000   | 37.25         | 40.13               |
| Sample_4    | 283        | 283.339996  | 282.39        | 285.06              |
| Sample_5    | 296        | 300.489990  | 300.79        | 301.51              |
| ...         | ...        | ...         | ...           | ...                 |
| Sample_2996 | 711        | 709.090027  | 712.10        | 713.16              |
| Sample_2997 | 1023       | 1008.340027 | 1006.00       | 999.29              |
| Sample_2998 | 1054       | 1048.430054 | 1048.04       | 1051.75             |
| Sample_2999 | 483        | 480.959991  | 472.63        | 459.36              |
| Sample_3000 | 1000       | 999.469971  | 1000.90       | 1001.79             |

|             | XGB_Error | RF_Error | LR_Error |
|-------------|-----------|----------|----------|
| Sample_1    | 0.15      | 4.56     | 5.48     |
| Sample_2    | 1.47      | 0.49     | 2.45     |
| Sample_3    | 0.02      | 4.25     | 7.13     |
| Sample_4    | 0.34      | 0.61     | 2.06     |
| Sample_5    | 4.49      | 4.79     | 5.51     |
| ...         | ...       | ...      | ...      |
| Sample_2996 | 1.91      | 1.11     | 2.16     |

...


- XGBoost: 999.47 cycles (sai số: 0.53)
- Random Forest: 1000.89 cycles (sai số: 0.89)
- Linear Regression: 1001.79 cycles (sai số: 1.79)

Mô hình tốt nhất: XGBoost (sai số: 0.53)

Hình 5.20 Dự đoán kết quả chi tiết

Kết quả cho thấy thực tế pin còn bao nhiêu, mô hình dự đoán còn bao nhiêu và sai số của từng mô hình, từ kết quả trên mô hình cho kết quả tốt nhất là XGBoost.

Biểu đồ Actual vs Predicted cho 3 mô hình tốt nhất.



Hình 5.21 Ba mô hình tốt nhất

Chấm nào càng gần đường chéo thì mô hình đó dự đoán càng chính xác với mẫu tương ứng.

Cuối cùng là thống kê hiệu suất của các mô hình.

### TÓM TẮT HIỆU SUẤT TRÊN CÁC MẪU TEST:

=====

#### XGBoost:

- Sai số trung bình: 2.08 cycles
- Sai số lớn nhất: 29.65 cycles
- Sai số nhỏ nhất: 0.00 cycles
- Độ lệch chuẩn: 2.56 cycles

#### Random Forest:

- Sai số trung bình: 2.67 cycles
- Sai số lớn nhất: 25.97 cycles
- Sai số nhỏ nhất: 0.00 cycles
- Độ lệch chuẩn: 3.62 cycles

#### Linear Regression:

- Sai số trung bình: 4.40 cycles
- Sai số lớn nhất: 25.72 cycles
- Sai số nhỏ nhất: 0.09 cycles
- Độ lệch chuẩn: 5.46 cycles

#### SỐ LẦN TỪNG MÔ HÌNH DỰ ĐOÁN TỐT NHẤT:

- XGBoost: 1463/3000 lần (48.8%)
- Random Forest: 1297/3000 lần (43.2%)
- Linear Regression: 240/3000 lần (8.0%)

Kết luận: Mô hình XGBoost cho kết quả dự đoán tốt nhất trên các mẫu test này.

Hình 5.22 Hiệu suất các mô hình

## 5.4 Phân tích mô hình Random Forest (Feature importance và sai số Residuals)

### 5.4.1 Mục tiêu

Phần này sẽ tiến hành phân tích vì sao thuật toán Random Forest dự đoán tốt hoặc xấu, ngoài ra còn giúp xác định đặc trưng nào ảnh hưởng nhiều nhất đến dự đoán RUL, và cuối cùng là kiểm tra chất lượng dự đoán thông qua sai số.

### 5.4.2 Nguyên tắc Feature Importance trong Random Forest

Thuật toán Random Forest là tập hợp nhiều cây quyết định, mỗi cây chia nhánh theo các đặc trưng để giảm sai số.

Feature importance trong Random Forest được tính theo các nguyên tắc:

- Mỗi lần một đặc trưng được dùng để split, mô hình đo mức giảm độ impurity sau split.
- Với bài toán hồi quy, impurity thường liên quan đến giảm MSE/Variance tại node.
- Độ quan trọng của 1 feature được tính bằng tổng mức giảm impurity do feature đó tạo ra trên tất cả các node, cộng dồn qua tất cả cây sau đó chuẩn hóa sao cho tổng importance xấp xỉ bằng 1.


Ý nghĩa: Feature càng có importance càng cao thì càng thường xuyên xuất hiện ở các split quan trọng và làm giảm sai số nhiều.

### **5.4.3 Kết quả**

```

Top 20 feature importance:
Cycle_Index          0.998449
Discharge_Rolling_Mean_10 0.001138
Max. Voltage Dischar. (V) 0.000054
Efficiency_Ratio     0.000044
Voltage_Drop_Rate    0.000043
Charging time (s)    0.000041
Discharge Time (s)   0.000040
Min. Voltage Charg. (V) 0.000037
Time at 4.15V (s)   0.000037
Decrement 3.6-3.4V (s) 0.000035
Discharge_Rolling_Std_10 0.000025
Prev_Cycle_Discharge 0.000022
Time constant current (s) 0.000020
Discharge_Drop_Rate  0.000016
dtype: float64

```





Hình 5.23 Feature importance (Top 20) của Random Forest

Hình minh họa mức độ đóng góp của từng đặc trưng vào dự đoán của Random Forest (tính theo tổng mức giảm impurity/MSE khi đặc trưng được dùng để chia nhánh, chuẩn hóa tổng bằng 1).

Kết quả cho thấy Cycle\_index chiếm ưu thế cao nhất với độ quan trọng xấp xỉ 0.998449 cao hơn các đặc trưng còn lại điều này thể hiện mô hình dựa mạnh vào thông tin chu kỳ để suy ra RUL.

Phân bố residuals (Actual - Predicted) của Random Forest:



Hình 5.24 Phân bố sai số



Các điểm dữ liệu phân bố bám sát đường  $y = x$  cho thấy mô hình Random Forest dự đoán tốt và sai lệch không lớn đối với đa số mẫu. Một số điểm lệch khỏi đường tham chiếu thể hiện các trường hợp mô hình dự đoán chưa chính xác tuyệt đối, phù hợp với phân bố residuals ở hình trước.

Từ phân tích Feature Importance, có thể thấy mô hình Random Forest trong phiên bản v1 phụ thuộc rất mạnh vào đặc trưng **Cycle\_Index**, trong khi các đặc trưng còn lại (bao gồm các đặc trưng được tạo thêm từ Feature Engineering) chỉ đóng góp ở mức nhỏ. Điều này giải thích vì sao mô hình đạt hiệu suất cao trên tập kiểm tra khi RUL có quan hệ chặt với số chu kỳ. Đồng thời, phân bố sai số (Residuals) tập trung chủ yếu quanh 0 và biểu đồ Actual vs Predicted bám sát đường tham chiếu  $y = x$  cho thấy mô hình dự đoán ổn định và sai lệch không lớn đối với phần lớn mẫu dữ liệu. Tuy nhiên việc Cycle\_Index chi phối quá mạnh cũng gợi ý nguy cơ mô hình học theo chu kỳ thay vì học từ các tín hiệu phản ánh trạng thái pin, vì vậy ở chương tiếp theo nhóm xây dựng phiên bản mở rộng theo hướng giảm phụ thuộc vào Cycle\_Index và tăng vai trò của các đặc trưng trạng thái nhằm đánh giá tính thực tế và khả năng tổng quát hóa của mô hình.

## CHƯƠNG 6. MỞ RỘNG

### 6.1 Mục tiêu

Vì mô hình phụ thuộc quá mạnh vào `Cycle_index` nên dễ dẫn đến mô hình sẽ học theo chu kỳ hơn là học từ trạng thái của pin. Cách học này giúp kết quả trên tập test trở nên rất tốt khi dữ liệu train và test có cùng phân phối, nhưng đồng thời tiềm ẩn rủi ro mô hình học theo chu kỳ (học vẹt) thay vì học từ các đặc trưng phản ánh trạng thái suy giảm thật sự của pin (điện áp, thời gian sạc/xả, xu hướng biến thiên...). Vì vậy, chương 6 được xây dựng với mục tiêu mở rộng theo hướng đánh giá thực tế hơn: giảm sự phụ thuộc vào `Cycle_Index`, ép mô hình khai thác các tín hiệu trạng thái pin, từ đó kiểm tra khả năng dự đoán của mô hình khi không còn đặc trưng mạnh mang tính định danh chu kỳ. Phiên bản này đóng vai trò như một kịch bản khó hơn nhưng thực tế hơn để đo mức độ mô hình thực sự hiểu dữ liệu và tổng quát hóa tốt.

### 6.2 Quy trình thực hiện

Để đảm bảo tính công bằng khi so sánh thì nhóm đã sử dụng tập dữ liệu sau tiền xử lý và Feature Engineering (vì đã loại bỏ cột `Cycle_index`), kiểm tra chất lượng, chia dữ liệu và chuẩn hóa tương tự như phiên bản trước. Tuy nhiên thay vì dữ nguyên toàn bộ đặc trưng thì nhóm đã loại bỏ cột `Cycle_index` khỏi tập đặc trưng khi huấn luyện và đánh giá mô hình.

- Việc loại bỏ sẽ giúp mô hình giảm tình trạng dựa quá nhiều vào số thứ tự chu kỳ để suy ra RUL.
- Bắt mô hình phải học từ các đặc trưng mô tả trạng thái vận hành và mức suy giảm của pin.
- Đây là sự thay đổi làm cho bài toán trở nên khó hơn cũng như thực tế hơn đồng thời cho phép đánh giá mô hình theo hướng sát với bối cảnh ứng dụng.


Sau đó tiến hành huấn luyện mô hình với các thuật toán học máy và học sâu trên dữ liệu đã được xóa cột `cycle_index`. Vì không còn cột đặc trưng này mô hình cần các tín hiệu thay thế để nắm bắt xu hướng suy giảm theo thời gian.

### 6.3 Kết quả thực nghiệm

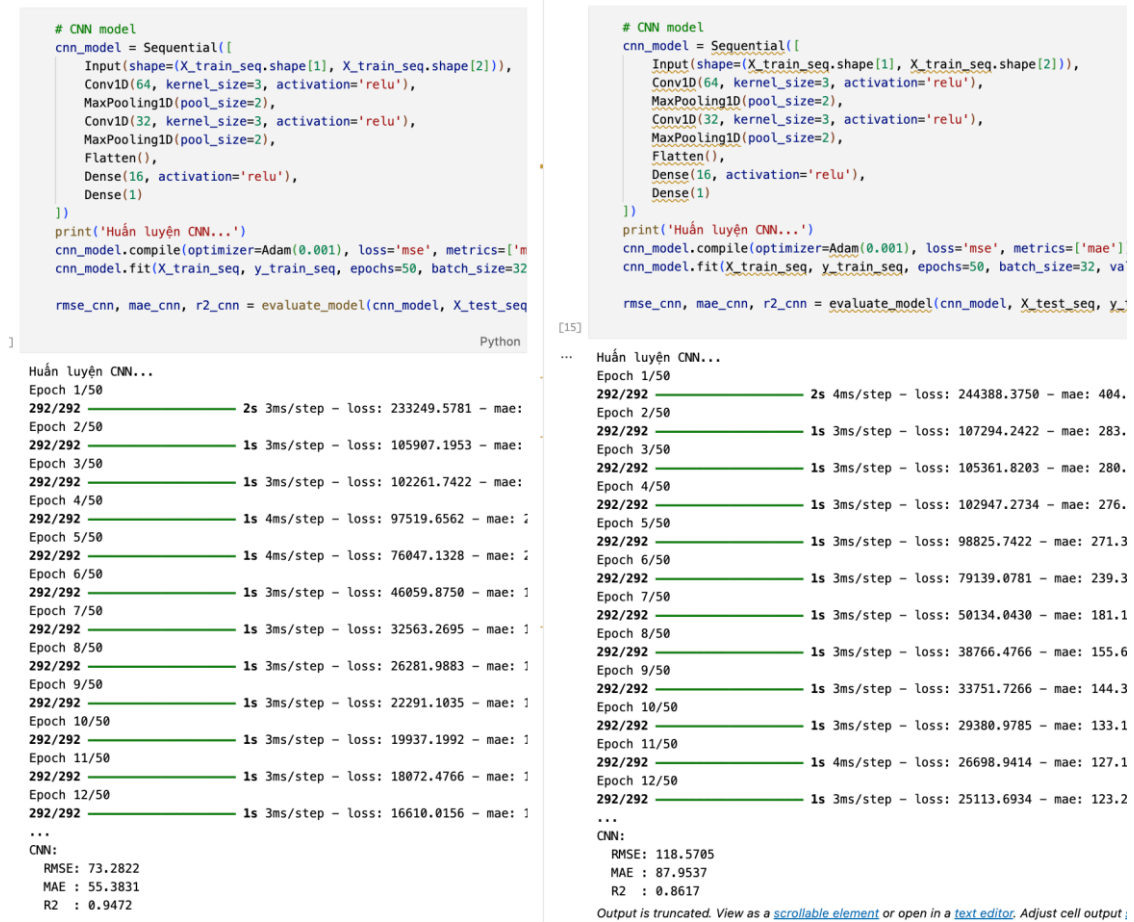


Hình 6.1 Kết quả với các mô hình học máy

Đối với nhóm mô hình học máy truyền thống, thì mức sai số tăng mạnh (bên phải) khi loại bỏ `cycle_index` cho thấy mô hình tuyến tính khó mô tả đầy đủ quan hệ phi tuyến tính giữa các đặc trưng trạng thái và giá trị URL trong điều kiện không còn thông tin chu kỳ trực tiếp. Ngược lại đối với mô hình ensemble (Random Forest) lại cho kết quả vượt trội, dựa trên cây khai thác hiệu quả các đặc trưng còn lại ngay cả khi bỏ cột đặc trưng `cycle_index`.



Hình 6.2 Kết quả mô hình LSTM



Hình 6.3 Kết quả mô hình CNN



Hình 6.4 Kết quả mô hình XGBoost

Còn đối với nhóm mô hình học sâu thì cả 3 mô hình vẫn cho ra kết quả khá khả quan vẫn giữ được hiệu năng rất cao tuy nhiên vẫn thấp hơn mô hình Random Forest.

| === BẢNG SO SÁNH CHI TIẾT ===                             |         |         |        |
|-----------------------------------------------------------|---------|---------|--------|
|                                                           | RMSE    | MAE     | R2     |
| Linear Regression                                         | 7.0582  | 4.4195  | 0.9995 |
| Random Forest                                             | 4.4258  | 2.5785  | 0.9998 |
| LSTM                                                      | 20.0067 | 14.2449 | 0.9961 |
| GRU                                                       | 13.1606 | 8.8896  | 0.9983 |
| CNN                                                       | 73.2822 | 55.3831 | 0.9472 |
| XGBoost                                                   | 3.3522  | 2.1074  | 0.9999 |
| === KẾT QUẢ ===                                           |         |         |        |
| Mô hình tốt nhất (RMSE thấp nhất): XGBoost (RMSE: 3.3522) |         |         |        |
| Mô hình tốt nhất (R2 cao nhất): XGBoost (R2: 0.9999)      |         |         |        |
| === PHÂN TÍCH CHI TIẾT ===                                |         |         |        |
| Linear Regression:                                        |         |         |        |
| - RMSE: 7.0582 (Tốt)                                      |         |         |        |
| - MAE: 4.4195 (Tốt)                                       |         |         |        |
| - R2: 0.9995 (Xuất sắc)                                   |         |         |        |
| Random Forest:                                            |         |         |        |
| - RMSE: 4.4258 (Tốt)                                      |         |         |        |
| - MAE: 2.5785 (Tốt)                                       |         |         |        |
| - R2: 0.9998 (Xuất sắc)                                   |         |         |        |
| LSTM:                                                     |         |         |        |
| ...                                                       |         |         |        |
| - RMSE: 20.0067 (Tốt)                                     |         |         |        |
| - MAE: 14.2449 (Tốt)                                      |         |         |        |
| - R2: 0.9961 (Xuất sắc)                                   |         |         |        |
| GRU:                                                      |         |         |        |
| ...                                                       |         |         |        |
| - RMSE: 13.1606 (Tốt)                                     |         |         |        |
| - MAE: 8.8896 (Tốt)                                       |         |         |        |
| - R2: 0.9983 (Xuất sắc)                                   |         |         |        |
| CNN:                                                      |         |         |        |
| ...                                                       |         |         |        |
| - RMSE: 73.2822 (Tốt)                                     |         |         |        |
| - MAE: 55.3831 (Tốt)                                      |         |         |        |
| - R2: 0.9472 (Xuất sắc)                                   |         |         |        |
| XGBoost:                                                  |         |         |        |
| ...                                                       |         |         |        |
| - RMSE: 3.3522 (Tốt)                                      |         |         |        |
| - MAE: 2.1074 (Tốt)                                       |         |         |        |
| - R2: 0.9999 (Xuất sắc)                                   |         |         |        |

Hình 6.5 So sánh kết quả các mô hình

Kết quả so sánh cho thấy mô hình Random Forest vẫn là mô hình cho kết quả khả quan nhất trong tất cả các mô hình. Tuy đã giảm phụ thuộc vào cột cycle\_index để các mô hình có thể học được các đặc trưng khác từ đó đưa ra được dự đoán thì tổng quan các mô hình có mô hình sẽ cho kết quả rất tệ vì không học được mối quan hệ phi tuyến tính còn mô hình vẫn cho kết quả khá tốt như Random Forest.

Tiếp theo là cho các mô hình dự đoán với dữ liệu ngẫu nhiên:

### DỰ ĐOÁN THỬ VỚI CÁC MÔ HÌNH TỐT NHẤT

Dự đoán cho 3000 mẫu ngẫu nhiên:


|             | Actual_RUL | XGBoost    | Random_Forest | Linear_Regression \ |
|-------------|------------|------------|---------------|---------------------|
| Sample_1    | 315        | 320.980011 | 328.04        | 255.63              |
| Sample_2    | 81         | 73.489998  | 76.54         | 121.01              |
| Sample_3    | 379        | 381.450012 | 380.64        | 429.38              |
| Sample_4    | 483        | 481.410004 | 486.55        | 397.51              |
| Sample_5    | 452        | 457.070007 | 453.65        | 457.84              |
| ...         | ...        | ...        | ...           | ...                 |
| Sample_2996 | 476        | 483.230011 | 480.88        | 477.96              |
| Sample_2997 | 645        | 641.369995 | 642.57        | 561.11              |
| Sample_2998 | 240        | 221.929993 | 229.16        | 287.93              |
| Sample_2999 | 652        | 659.619995 | 661.21        | 684.74              |
| Sample_3000 | 861        | 864.580017 | 861.68        | 808.74              |

|             | XGB_Error | RF_Error | LR_Error |
|-------------|-----------|----------|----------|
| Sample_1    | 5.98      | 13.04    | 59.37    |
| Sample_2    | 7.51      | 4.46     | 40.01    |
| Sample_3    | 2.45      | 1.64     | 50.38    |
| Sample_4    | 1.59      | 3.55     | 85.49    |
| Sample_5    | 5.07      | 1.65     | 5.84     |
| ...         | ...       | ...      | ...      |
| Sample_2996 | 7.23      | 4.88     | 1.96     |
| ...         | ...       | ...      | ...      |

- XGBoost: 864.58 cycles (sai số: 3.58)
- Random Forest: 861.68 cycles (sai số: 0.68)
- Linear Regression: 808.74 cycles (sai số: 52.26)

Mô hình tốt nhất: Random Forest (sai số: 0.68)


Hình 6.6 Dự đoán kết quả



Hình 6.7 Hiệu suất 3 mô hình

Cuối cùng là về phân tích Feature Importance và Residuals để kiểm chứng mô hình đã thực sự học từ các đặc trưng trạng thái khác mà không phải học từ Cycle\_index.

```
Top 20 feature importance:
Discharge_Rolling_Mean_10    0.863769
Prev_Cycle_Discharge         0.082440
Discharge Time (s)           0.036601
Decrement 3.6-3.4V (s)       0.005315
Time at 4.15V (s)            0.005168
Efficiency_Ratio              0.002823
Discharge_Rolling_Std_10     0.001373
Max. Voltage Dischar. (V)     0.000730
Voltage_Drop_Rate             0.000697
Min. Voltage Charg. (V)       0.000597
Charging time (s)             0.000227
Time constant current (s)     0.000148
Discharge_Drop_Rate           0.000113
dtype: float64
```





Hình 6.8 Feature Importance

Có thể thấy đặc trưng Discharge\_Rolling\_Mean\_10 là đặc trưng quan trọng nhất và dựa vào thông tin chu kỳ trước để dự đoán RUL. Và đặc trưng này đã được bổ sung vào khi thêm đặc trưng vật lý và đặc trưng thời gian.



Phân bố residuals (Actual - Predicted) của Random Forest:



Hình 6.9 Residuals

## 6.4 Kết luận

Qua toàn bộ quá trình thực hiện, nhóm đã xây dựng được một hệ thống dự đoán tuổi thọ còn lại của pin theo hướng bài bản và có tính kiểm chứng rõ ràng. Dự án bắt đầu từ việc khảo sát dữ liệu thô, làm sạch và chuẩn hóa dữ liệu đầu vào, sau đó tiến hành phân tích khám phá để hiểu đặc điểm phân bố, xu hướng biến thiên và các vấn đề tiềm ẩn trong dữ liệu (giá trị thiếu, nhiều, giá trị bất thường). Trên nền tảng đó nhóm thực hiện bước trích xuất và tạo đặc trưng nhằm chuyển dữ liệu ban đầu thành các biến có ý nghĩa hơn đối với bài toán dự đoán, bao gồm nhóm đặc trưng gắn với hành vi vận hành của pin hay còn gọi là đặc trưng vật lý (điện áp, thời gian sạc/xả, các ngưỡng điện áp đặc trưng) và nhóm đặc trưng mô tả tính chuỗi thời gian (xu hướng trung bình trượt, độ ổn định, sai phân, đặc trưng trễ). Việc tạo đặc trưng không chỉ giúp mô hình xác định rõ hơn trạng thái suy giảm theo thời gian mà còn góp phần tăng khả năng học được quan hệ phi tuyến giữa các biến đầu vào và giá trị cần dự đoán. Tiếp theo, nhóm xây dựng quy trình huấn luyện và đánh giá thống nhất: tách dữ liệu thành tập huấn luyện và kiểm tra theo một tỷ lệ cố định, thực hiện chuẩn hóa để đưa các đặc trưng về cùng thang đo nhằm đảm bảo tính ổn định khi học, và áp dụng nhiều nhóm mô hình khác nhau để so sánh hiệu quả. Nhóm mô hình được triển khai đa dạng từ các phương pháp truyền thống đến các mô hình có khả năng học phi tuyến mạnh và các mô hình học sâu cho dữ liệu chuỗi, nhờ đó quá trình thực nghiệm có tính bao quát và giúp lựa chọn được hướng tiếp cận phù hợp cho bài toán. Song song với đánh giá bằng các chỉ số định lượng, nhóm cũng chú trọng phân tích định tính thông qua việc kiểm tra độ quan trọng của đặc trưng và phân bố sai số dự đoán; điều này giúp giải thích mô hình học từ đâu, phát hiện hiện tượng mô hình phụ thuộc quá mạnh vào một số biến nhất định, đồng thời đánh giá sự ổn định của dự đoán trên tập kiểm tra thông qua hành vi của residuals và mối tương quan giữa giá trị dự đoán và giá trị thực tế. Nhờ cách làm này, kết quả của dự án không chỉ dừng lại ở việc đạt độ chính xác tốt mà còn thể hiện được tính minh bạch và khả năng diễn giải, cho phép rút ra các bài học quan trọng về vai trò của từng nhóm đặc trưng, mức độ ảnh hưởng của thông tin chu kỳ, cũng như điểm mạnh của các mô hình phi tuyến khi khai thác

dữ liệu trạng thái pin. Tóm lại, dự án đã hoàn thiện được một quy trình đầy đủ từ dữ liệu đến mô hình và phân tích sau mô hình, tạo ra một hướng tiếp cận có thể mở rộng trong thực tế: vừa dự đoán hiệu quả, vừa có cơ sở giải thích rõ ràng, đồng thời cho thấy cách cải tiến hợp lý để tăng độ tin cậy khi đưa mô hình vào các kịch bản ứng dụng.

Cuối cùng để trực quan hóa kết quả ở chương tiếp theo nhóm sẽ tiến hành demo trên nền tảng website sử dụng bằng streamlit với bài toán này để có cái nhìn tổng quan khi áp dụng vào thực tiễn (mang ý nghĩa tượng trưng).

## CHƯƠNG 7. DEMO WEBSITE HỆ THỐNG DỰ ĐOÁN

### 7.1 Mục tiêu

Nhằm nhu cầu trực quan hóa cách sử dụng thì nhóm đã triển khai sử dụng công cụ streamlit để tạo dựng một trang web đơn giản thân thiện để có thể sử dụng hệ thống phân tích và dự đoán RUL. Hệ thống hỗ trợ người dùng nhập dữ liệu theo 2 cách: nhập thủ công các thông số cần thiết và tải file định dạng csv (nội dung file phải chứa đủ các trường cần thiết để hệ thống có thể phân tích), giúp người dùng xem được các dữ liệu đã được nhập vào hệ thống, chỉnh sửa hoặc xóa nếu cần thiết, khi nhập đủ và đúng dữ liệu hệ thống sẽ thực hiện quy trình xử lý và chạy dự đoán RUL bằng mô hình đã được huấn luyện sau đó hiển thị kết quả cho người dùng. Ngoài ra hệ thống còn hiển thị chi tiết các dữ liệu trước và sau khi xử lý để người dùng có thể tiện theo dõi nếu muốn. Tóm lại hệ thống sẽ mang tính trực quan hóa quy trình áp dụng vào thực tiễn.

### 7.2 Tổng quan giao diện

Giao diện tổng quan khi chạy lên sẽ như sau:

**DEMO WEBSITE HỆ THỐNG DỰ ĐOÁN REMAINING USEFUL LIFE**

[Đã load mô hình vào hệ thống](#) [Deploy](#)

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rolling(window=10) ổn định).
- Tải file: CSV giống dữ liệu gốc (dù cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)
- Rolling\_Cycle\_Discharge = shift(Discharge Time, -1)

**Nhập thủ công** **Nhập nhanh**

Số dòng đã nhập: 0. Khuyến nghị:  $\geq 10$ . Tỷ lệ dữ liệu cần thiết: 0%.

**Nhập dữ liệu (7 cột gốc)**

Chọn chế độ nhập: nhập dữ liệu rồi nhấn Enter (submit) hoặc bấm nút bên dưới.

| Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) |
|--------------------|------------------------|---------------------------|-------------------------|
| VD: 2595.3         | VD: 1151.4885          | VD: 3.67                  | VD: 3.211               |

Time at 4.15V (s): VD: 5460.001. Time constant current (s): VD: 6755.01. Charging time (s): VD: 10777.82.

**Thao tác**


[Enter để thêm / lưu](#) [Lưu chính sửa](#) [Hủy sửa](#)

[Xóa tất cả](#) [Xóa dòng cuối](#)

Tải Dữ Liệu số rồi nhấn Enter để thêm nhanh (hoặc tải nếu đang tải)

Hình 7.1 Giao diện hệ thống

Hệ thống hỗ trợ người dùng với 2 chế độ nhập liệu là nhập thủ công và tải file dữ liệu lên hệ thống, đối với tải file thì có giao diện như sau:



Hình 7.2 Giao diện tải file dữ liệu

Đối với cả 2 cách nhập liệu thì sau khi nhập đủ hoặc tải đúng file dữ liệu lên hệ thống và bấm nút phân tích và dự đoán thì sẽ hiển thị được kết quả cho người dùng xem cũng như sẽ hiển thị quy trình dữ liệu được xử lý trước khi đưa vào model để chạy ra kết quả cuối, ngoài ra còn hỗ trợ các chức năng như xóa sửa dữ liệu nếu người dùng có nhu cầu thay đổi. Người dùng có thể tải file kết quả về nếu muốn, áp dụng cho cả chế độ nhập dữ liệu thủ công và tải file.

Khu vực bên trái là sidebar với các thông tin mô tả các thuộc tính thông số dữ liệu mà người dùng cần nhập vào để hệ thống có thể dự đoán được chính xác nhất cụ thể như sau

Mỗi hàng dữ liệu người dùng nhập vào tương ứng với 1 chu kỳ bao gồm các trường:

- **Discharge Time (s):** Thời gian xả (giây).
- **Decrement 3.6–3.4V (s):** Thời gian điện áp giảm từ 3.6V xuống 3.4V (giây).
- **Max. Voltage Dischar. (V):** Điện áp lớn nhất khi xả (V).
- **Min. Voltage Charg. (V):** Điện áp nhỏ nhất khi sạc (V).
- **Time at 4.15V (s):** Thời gian tại ngưỡng 4.15V (giây).
- **Time constant current (s):** Thời gian dòng không đổi (CC) (giây).
- **Charging time (s):** Thời gian sạc (giây).

Ngoài ra còn có các Feature Engineering mà hệ thống tạo ra trong quá trình tính toán và những giá trị này đều được hệ thống tính toán tự động không cần người dùng nhập giá trị.

### 7.3 Hướng dẫn sử dụng

Khi người dùng vào hệ thống nếu chọn nhập thủ công thì sẽ thực hiện theo quy trình như sau:

- Người dùng có thể nhập từng giá trị vào từng ô trên giao diện hoặc lựa chọn nhập nhanh để nhập 1 lần hệ thống sẽ tự điền dữ liệu tương ứng vào các trường tương ứng (yêu cầu nhập đúng thứ tự thuộc tính).
- Khi nhập xong hệ thống sẽ hiển thị lại dữ liệu của người dùng đã nhập vào bên dưới, người dùng có thể xóa sửa nếu muốn.
- Nhập ít nhất 10 dữ liệu vì để các đặc trưng có dạng rolling cần đủ lịch sử chu kỳ để hoạt động ổn định.
- Khi điền đủ và ấn nút phân tích và dự đoán, chờ một chút hệ thống sẽ sử dụng model đã được huấn luyện và chạy với dữ liệu người dùng nhập vào sau khi đã được xử lý phù hợp và trả ra kết quả cuối ra giao diện cho người dùng xem.

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rolling>window=10) ổn định).
- Tải file: CSV giống dữ liệu gốc (đu cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)
- Deriv\_Furto\_Derivative = deriv(Derivative Time)

**Thao tác**


Enter để thêm / lưu    Lưu chính sửa    Hủy sửa    Xóa tất cả    Xóa dòng cuối

Tip: Dán 7 số rồi nhấn Enter để thêm nhanh (hoặc lưu nếu đang sửa).

**Danh sách dữ liệu đã nhập**


| Chọn sửa                 | STT | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) |
|--------------------------|-----|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|
| <input type="checkbox"/> | 1   | 2595.3             | 1151.4885              | 3.67                      | 3.211                   | 5460.001          | 6755.01                   | 10777.82          |
| <input type="checkbox"/> | 2   | 2587.94            | 1231.999               | 3.661                     | 3.223                   | 5383.009          | 6678.02                   | 10856.83          |
| <input type="checkbox"/> | 3   | 2565.31            | 1186.4965              | 3.664                     | 3.221                   | 5430.007          | 6740.99                   | 10999.07          |
| <input type="checkbox"/> | 4   | 2652.99            | 1364.991               | 3.652                     | 3.233                   | 5340.993          | 6664                      | 11018.02          |
| <input type="checkbox"/> | 5   | 2590.5             | 1169.024               | 3.667                     | 3.206                   | 5446.016          | 6734.02                   | 10759.26          |
| <input type="checkbox"/> | 6   | 2590.98            | 1154.976               | 3.667                     | 3.224                   | 5452.992          | 6727.01                   | 10819.42          |
| <input type="checkbox"/> | 7   | 2609.47            | 1372                   | 3.65                      | 3.228                   | 5348              | 6678.02                   | 11078.56          |
| <input type="checkbox"/> | 8   | 2590.02            | 1274.016               | 3.657                     | 3.23                    | 5355.008          | 6664                      | 10864             |
| <input type="checkbox"/> | 9   | 2590.02            | 1239.007               | 3.66                      | 3.225                   | 5376              | 6678.01                   | 10821.98          |
| <input type="checkbox"/> | 10  | 2566.08            | 1161.983               | 3.667                     | 3.224                   | 5452.992          | 6740.99                   | 10938.33          |

Hình 7.3 Nhập dữ liệu thủ công



Hình 7.4 Kết quả phân tích

Ngoài kết quả cuối cùng hệ thống còn cho người dùng tùy chọn xem dữ liệu đã được xử lý trước khi đưa vào model để chạy ra kết quả cuối cùng.



Hình 7.5 Dữ liệu phân tích

Đối với bảng dữ liệu xử lý dưới cùng là dữ liệu sau khi làm sạch bằng các thực hiện bù khuyết cho các giá trị thiếu sinh ra trong quá trình tạo feature, lọc bỏ các dòng không hợp lệ theo điều kiện. Còn bảng dữ liệu phía trên là bảng thể hiện tập đặc trưng cuối cùng mà hệ thống chuẩn bị đưa vào mô hình với các xử lý như loại các cột không dùng làm đầu vào dự đoán (RUL, Cycle\_index) chỉ giữ lại các cột đặc trưng cần thiết cho model bao gồm các cột gốc và các feature đã tạo thêm.

Còn đối với nhập dữ liệu bằng cách tải file lên thì yêu cầu file csv cần định dạng gốc với dữ liệu gốc, nếu thiếu bất kì cột nào cần thiết sẽ làm cho hệ thống không chạy được. Mục tiêu của cách này là thay vì nhập thủ công thì sẽ xây dựng pipeline cho phép hệ thống chạy dự đoán tự động với số lượng lớn dữ liệu đầu vào, nhằm giúp tiết kiệm thời gian và công sức bỏ ra.

Quy trình thực hiện chi tiết như sau:

- Người dùng truy cập giao diện chọn file và chọn file dữ liệu tương ứng
- Ấn nút chạy và đợi hệ thống phân tích và cho ra kết quả.

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rolling>window=10) ổn định).
- Tải file: CSV giống dữ liệu gốc (đủ cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)

• *Bew. Cycle Discharge = diff(Discharge Time - 1)*

**DEMO HỆ THỐNG DỰ ĐOÁN REMAINING USEFUL LIFE**

Đã load mô hình vào hệ thống Deploy

👉 Nhập thủ công 📁 Tải file CSV

Tải file CSV (format giống dữ liệu gốc)

File phải có đủ cột (gồm Cycle\_Index và RUL). Hệ thống sẽ xử lý theo đúng pipeline và xuất file kết quả.

Chọn file CSV

Drag and drop file here  
Limit 200MB per file • CSV

Battery\_RUL\_processed.csv 1.2MB

Chạy dự đoán từ file

Xem trước 10 dòng đầu:

|   | Cycle_Index | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | RUL      |
|---|-------------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|----------|
| 0 | 1           | 2595.3             | 1151.4865              | 3.67                      |                         | 3.211             | 5460.001                  | 6755.01           | 10777.82 |
| 1 | 1           | 2587.94            | 1231.999               | 3.661                     |                         | 3.223             | 5383.009                  | 6678.02           | 10856.83 |
| 2 | 1           | 2565.31            | 1186.4905              | 3.664                     |                         | 3.221             | 5439.007                  | 6740.99           | 10999.07 |
| 3 | 1           | 2652.99            | 1364.991               | 3.652                     |                         | 3.233             | 5340.993                  | 6664              | 11018.02 |
| 4 | 1           | 2590.5             | 1169.024               | 3.667                     |                         | 3.206             | 5446.016                  | 6734.02           | 10759.26 |
| 5 | 1           | 2590.98            | 1154.976               | 3.667                     |                         | 3.224             | 5452.992                  | 6727.01           | 10819.42 |
| 6 | 1           | 2609.47            | 1372                   | 3.65                      |                         | 3.228             | 5348                      | 6678.02           | 11078.56 |
| 7 | 1           | 2590.02            | 1274.016               | 3.657                     |                         | 3.23              | 5355.008                  | 6664              | 10864    |
| 8 | 1           | 2590.02            | 1239.007               | 3.66                      |                         | 3.225             | 5376                      | 6678.01           | 10821.98 |
| 9 | 1           | 2565.08            | 1161.983               | 3.667                     |                         | 3.214             | 5452.992                  | 6740.99           | 10938.33 |

Hình 7.6 Nhập dữ liệu tải file csv

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rolling>window=10) ổn định).
- Tải file: CSV giống dữ liệu gốc (đủ cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)

• *Bew. Cycle Discharge = diff(Discharge Time - 1)*

**DEMO HỆ THỐNG DỰ ĐOÁN REMAINING USEFUL LIFE**

Đã load mô hình vào hệ thống Deploy

Đánh giá (trên file upload)

RMSE: 20.8655      MAE: 7.4198      R<sup>2</sup>: 0.9958

Kết quả (một phần)

|   | % Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | RUL  | Efficiency_Ratio | Voltage_Drop_Rate | Discharge_Drop_Rate | Discharge_Rolling_Mean_10 | Discharge_Rolling_Std_10 | Prev_Cycle_Discharge | Predicted_RUL |
|---|----------------------|-------------------|---------------------------|-------------------|------|------------------|-------------------|---------------------|---------------------------|--------------------------|----------------------|---------------|
| 0 | 3.211                | 5460.001          | 6755.01                   | 10777.82          | 1112 | 0.2408           | 0.0002            | -19.3               | 2585.494                  | 13.2216                  | 2595.3               | 1109.925      |
| 1 | 3.223                | 5438.016          | 6712.99                   | 10815.74          | 1107 | 0.2382           | 0.0002            | -19.3               | 2585.494                  | 13.2216                  | 2595.3               | 1107.475      |
| 2 | 3.213                | 5424.991          | 6706.02                   | 10772.99          | 1107 | 0.2417           | 0.0002            | 28                  | 2585.494                  | 13.2216                  | 2576                 | 1107.775      |
| 3 | 3.219                | 5453.993          | 6740.99                   | 10836             | 1107 | 0.2364           | 0.0002            | -41.98              | 2585.494                  | 13.2216                  | 2604                 | 1107.04       |
| 4 | 3.214                | 5452.992          | 6740.99                   | 10938.33          | 1107 | 0.2346           | 0.0002            | 4.06                | 2585.494                  | 13.2216                  | 2562.02              | 1107.575      |
| 5 | 3.225                | 5376              | 6678.01                   | 10821.98          | 1133 | 0.2393           | 0.0002            | 23.94               | 2585.494                  | 13.2216                  | 2566.08              | 1108.875      |
| 6 | 3.23                 | 5355.008          | 6664                      | 10864             | 1113 | 0.2384           | 0.0002            | 0                   | 2585.494                  | 13.2216                  | 2590.02              | 1109.96       |
| 7 | 3.226                | 5404.001          | 6706.02                   | 10909.09          | 1111 | 0.2374           | 0.0002            | 0                   | 2585.494                  | 13.2216                  | 2590.02              | 1109.15       |
| 8 | 3.224                | 5452.992          | 6727.01                   | 10819.42          | 1107 | 0.2395           | 0.0002            | 0.96                | 2585.494                  | 13.2216                  | 2590.02              | 1107.41       |
| 9 | 3.206                | 5446.016          | 6734.02                   | 10759.26          | 1104 | 0.2408           | 0.0002            | -0.48               | 2585.494                  | 13.2216                  | 2590.98              | 1107.185      |

Tải file kết quả (CSV)

Chi tiết xử lý

- Chi tiết - X đưa vào model
- Chi tiết - Dữ liệu sau xử lý (MôI + lọc Voltage\_Drop\_Rate < 0)

Hình 7.7 Kết quả dự đoán trên file



**DEMO HỆ THỐNG DỰ ĐOÁN REMAINING USEFUL LIFE** Bắt load mô hình vào hệ thống Deploy

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rollingwindow=10 ổn định).
- Tải file: CSV giống dữ liệu gốc (đủ cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)
- Raw\_Cycle\_Discharge = subit(Discharge Time, 1)

**Chi tiết xử lý**

Chi tiết - X đưa vào model

|   | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | Efficiency_Ratio | Voltage_Drop_Rate | Discharge_Drop_Rate | Discharge_Rolling_Mean_1 |
|---|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|------------------|-------------------|---------------------|--------------------------|
| 0 | 2595.3             | 1151.4885              | 3.67                      | 3.211                   | 5460.001          | 6755.01                   | 10777.82          | 0.2408           | 0.0002            | -19.3               | 2585.49                  |
| 1 | 2576               | 1197.024               | 3.663                     | 3.223                   | 5418.026          | 6712.99                   | 10815.74          | 0.2382           | 0.0002            | -19.3               | 2585.49                  |
| 2 | 2604               | 1186.4955              | 3.666                     | 3.213                   | 5424.991          | 6706.02                   | 10772.99          | 0.2417           | 0.0002            | 28                  | 2585.49                  |
| 3 | 2562.02            | 1140.991               | 3.666                     | 3.219                   | 5452.993          | 6740.99                   | 10836             | 0.2364           | 0.0002            | -41.98              | 2585.49                  |
| 4 | 2566.08            | 1161.983               | 3.667                     | 3.214                   | 5452.992          | 6740.99                   | 10938.33          | 0.2346           | 0.0002            | 4.06                | 2585.49                  |
| 5 | 2590.02            | 1239.007               | 3.66                      | 3.225                   | 5376              | 6678.01                   | 10821.98          | 0.2393           | 0.0002            | 23.94               | 2585.49                  |
| 6 | 2590.02            | 1274.016               | 3.657                     | 3.23                    | 5355.008          | 6664                      | 10864             | 0.2384           | 0.0002            | 0                   | 2585.49                  |
| 7 | 2590.02            | 1189.984               | 3.664                     | 3.226                   | 5404.001          | 6706.02                   | 10909.09          | 0.2374           | 0.0002            | 0                   | 2585.49                  |
| 8 | 2590.98            | 1154.976               | 3.667                     | 3.224                   | 5452.992          | 6727.01                   | 10819.42          | 0.2395           | 0.0002            | 0.96                | 2585.49                  |
| 9 | 2590.5             | 1189.024               | 3.667                     | 3.206                   | 5446.016          | 6734.02                   | 10759.26          | 0.2408           | 0.0002            | -0.48               | 2585.49                  |

Chi tiết - Dữ liệu sau xử lý (bfill + lọc Voltage\_Drop\_Rate < 0)

|   | Cycle_Index | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | RUL  | Efficiency_Ratio | Voltage_Drop_Rate | Discharge_Drop_Rate | Dis |
|---|-------------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|------|------------------|-------------------|---------------------|-----|
| 0 | 1           | 2595.3             | 1151.4885              | 3.67                      | 3.211                   | 5460.001          | 6755.01                   | 10777.82          | 1112 | 0.2408           | 0.0002            | -19.3               |     |
| 1 | 1           | 2576               | 1197.024               | 3.663                     | 3.223                   | 5418.026          | 6712.99                   | 10815.74          | 1107 | 0.2382           | 0.0002            | -19.3               |     |
| 2 | 1           | 2604               | 1186.4955              | 3.666                     | 3.213                   | 5424.991          | 6706.02                   | 10772.99          | 1107 | 0.2417           | 0.0002            | 28                  |     |
| 3 | 1           | 2562.02            | 1140.991               | 3.666                     | 3.219                   | 5452.993          | 6740.99                   | 10836             | 1107 | 0.2364           | 0.0002            | -41.98              |     |
| 4 | 1           | 2566.08            | 1161.983               | 3.667                     | 3.214                   | 5452.992          | 6740.99                   | 10938.33          | 1107 | 0.2346           | 0.0002            | 4.06                |     |
| 5 | 1           | 2590.02            | 1239.007               | 3.66                      | 3.225                   | 5376              | 6678.01                   | 10821.98          | 1133 | 0.2393           | 0.0002            | 23.94               |     |
| 6 | 1           | 2590.02            | 1274.016               | 3.657                     | 3.23                    | 5355.008          | 6664                      | 10864             | 1113 | 0.2384           | 0.0002            | 0                   |     |
| 7 | 1           | 2590.02            | 1189.984               | 3.664                     | 3.226                   | 5404.001          | 6706.02                   | 10909.09          | 1111 | 0.2374           | 0.0002            | 0                   |     |

Hình 7.8 Dữ liệu xử lý chi tiết

Từ các kết quả trực quan trên hệ thống người dùng có thể tải dữ liệu kết quả về máy dưới định dạng csv nhằm các mục đích khác.

**DEMO HỆ THỐNG DỰ ĐOÁN REMAINING USEFUL LIFE** Bắt load mô hình vào hệ thống Deploy

**Hướng dẫn nhanh**

- Nhập thủ công: nhập theo từng dòng và đủ các số liệu cần thiết (khuyến nghị  $\geq 10$  dòng để rollingwindow=10 ổn định).
- Tải file: CSV giống dữ liệu gốc (đủ cột, gồm Cycle\_Index và RUL).

**Mô tả các thông số cần thiết**

- Discharge Time (s): Thời gian xả (giây).
- Decrement 3.6-3.4V (s): Thời gian giảm điện áp từ 3.6V xuống 3.4V.
- Max. Voltage Dischar. (V): Điện áp lớn nhất khi xả.
- Min. Voltage Charg. (V): Điện áp nhỏ nhất khi sạc.
- Time at 4.15V (s): Thời gian tại ngưỡng 4.15V.
- Time constant current (s): Thời gian dòng không đổi (CC).
- Charging time (s): Thời gian sạc (giây).

**Feature Engineering (hệ thống tự tính và xử lý)**

- Efficiency\_Ratio = Discharge Time / Charging time
- Voltage\_Drop\_Rate = (Max Voltage Dischar - Min Voltage Charg) / Discharge Time
- Discharge\_Drop\_Rate = diff(Discharge Time)
- Discharge\_Rolling\_Mean\_10 = rolling mean(window=10)
- Discharge\_Rolling\_Std\_10 = rolling std(window=10)
- Raw\_Cycle\_Discharge = subit(Discharge Time, 1)

**Tải file CSV (format giống dữ liệu gốc)**

File phải có đủ cột (gồm Cycle\_Index và RUL). Hệ thống sẽ xử lý theo đúng pipeline và xuất file kết quả.

Chọn file CSV: Cloud Drive Ứng dụng Màn hình n... Tải liệu Video Tài về minhquan 6\_JMKL\_202... DACNTT C Cloud NLP TEMP TEMP2

Lưu thành: **predictions\_from\_file.csv** Thư mục Thư mục Mới Hủy Lưu

Thư mục: Source\_Project STUDY TDTU TEMP TEMP2 TEXT\_FILE Video

|   | Cycle_Index | Discharge Time (s) | Decrement 3.6-3.4V (s) | Max. Voltage Dischar. (V) | Min. Voltage Charg. (V) | Time at 4.15V (s) | Time constant current (s) | Charging time (s) | RUL  |
|---|-------------|--------------------|------------------------|---------------------------|-------------------------|-------------------|---------------------------|-------------------|------|
| 0 |             | 5460.001           | 6755.01                | 10777.82                  | 1112                    |                   |                           |                   |      |
| 1 |             | 5383.009           | 6678.02                | 10866.83                  | 1107                    |                   |                           |                   |      |
| 2 |             | 5439.007           | 6740.99                | 10999.07                  | 1107                    |                   |                           |                   |      |
| 3 |             | 5340.993           | 6664                   | 11018.02                  | 1107                    |                   |                           |                   |      |
| 4 |             | 5446.016           | 6734.02                | 11079.26                  | 1102                    |                   |                           |                   |      |
| 5 |             | 5452.992           | 6727.01                | 10819.42                  | 1107                    |                   |                           |                   |      |
| 6 | 1           | 5405.01            | 1372                   | 3.63                      | 3.228                   | 5348              | 6678.02                   | 11079.36          | 1102 |
| 7 | 1           | 2590.02            | 1274.016               | 3.657                     | 3.23                    | 5355.008          | 6664                      | 10864             | 1113 |
| 8 | 1           | 2590.02            | 1239.007               | 3.66                      | 3.225                   | 5376              | 6678.01                   | 10821.98          | 1133 |
| 9 | 1           | 2566.08            | 1161.983               | 3.667                     | 3.214                   | 5452.992          | 6740.99                   | 10938.33          | 1107 |

Hình 7.9 Tải kết quả phân tích

## 7.4 Ý nghĩa

- Hệ thống thể hiện rõ được khả năng trong việc tiếp nhận dữ liệu theo hai cách (nhập thủ công hoặc tải tệp CSV), sau đó thực hiện xử lý theo pipeline và đưa ra kết quả dự đoán RUL. Từ góc nhìn người dùng, quy trình này giúp đóng gói toàn bộ các bước kỹ thuật (kiểm tra dữ liệu, chuẩn hóa, tạo đặc trưng, lọc lỗi) thành một luồng thao tác trực quan. Nhờ đó, người dùng

không cần hiểu sâu về mô hình học máy vẫn có thể thực hiện dự đoán theo đúng chuẩn dữ liệu yêu cầu và nhận được đầu ra phục vụ phân tích.

- Hệ thống không chỉ dự đoán kết quả mà còn hỗ trợ kiểm tra tính hợp lệ của dữ liệu đầu vào và thể hiện các bảng chi tiết xử lý theo từng bước. Việc hiển thị dữ liệu sau khi chuẩn hoá (ví dụ bfill, loại dòng lỗi) và dữ liệu cuối cùng đưa vào mô hình giúp minh bạch quy trình, giúp người dùng hiểu được vì sao dữ liệu được chấp nhận hoặc bị loại, từ đó hạn chế sai sót khi nhập liệu, tránh dự đoán trên dữ liệu không đạt yêu cầu. Điều này làm tăng độ tin cậy của kết quả vì dự đoán được thực hiện trên dữ liệu đã qua kiểm soát chất lượng theo cùng quy tắc xử lý.
- Hệ thống góp phần chứng minh tính sẵn sàng triển khai của mô hình trong môi trường sử dụng: hệ thống cung cấp thao tác quản lý dữ liệu theo dòng (thêm, sửa, huỷ sửa, xoá) hỗ trợ nhập nhanh để tiết kiệm thời gian và cho phép tải dữ liệu hàng loạt qua CSV. Đây là những đặc trưng gần với nhu cầu vận hành thực tế, nơi dữ liệu có thể được cập nhật liên tục theo từng chu kỳ hoặc được tổng hợp từ file. Nhờ đó hệ thống không chỉ dừng ở việc chạy mô hình, mà còn cho thấy khả năng hỗ trợ người dùng thao tác và theo dõi dữ liệu một cách có hệ thống.

Ngoài ra bài toán dự đoán RUL có tính thực tế cao vì liên quan trực tiếp đến nhu cầu theo dõi tuổi thọ còn lại của pin để hỗ trợ bảo trì, lập kế hoạch thay thế và giảm rủi ro hỏng hóc bất ngờ. Trong thực tế, dữ liệu đầu vào thường được thu từ hệ thống đo/ghi log (thiết bị đo, BMS, hoặc dữ liệu thử nghiệm theo chu kỳ) sau đó trích xuất ra các chỉ số đặc trưng phù hợp trước khi đưa vào mô hình. Yêu cầu dữ liệu đúng định dạng không làm bài toán kém thực tế mà phản ánh đúng quy trình triển khai cần có dữ liệu đủ chất lượng, được chuẩn hoá và thống nhất theo pipeline. Hệ thống tập trung vào luồng nhập liệu xử lý dự đoán, giúp mô hình có thể ứng dụng trong bối cảnh có dữ liệu đo đạc hoặc dữ liệu log tương ứng.

## TÀI LIỆU THAM KHẢO

Tiếng Việt

[\[1\] Dự Báo Tuổi Thọ Pin Lithium-Ion Xe Ô Tô Điện Dựa Trên Thuật Toán Hồi Quy Tuyến Tính — Võ Thanh Hà, Phạm Thị Giang, Đào Thanh Toàn. Hội nghị Quốc gia REV-ECIT 2022.](#)

[\[2\] Ước Lượng Trạng Thái Sạc Pin Li-ion Dựa Trên Thuật Toán VFFRLS và Mạng Nơ-ron — bài đăng trên tạp chí của Trường Đại học Công nghiệp Hà Nội.](#)

Tiếng Anh

[\[3\] Remaining Useful Life Prediction for Lithium-ion Battery: A Deep Learning Approach — Lei Ren et al., IEEE Access, 2018.](#)

[\[4\] Prediction of Remaining Useful Life for Lithium-Ion Battery with Multiple Health Indicators — C Su et al., 2021.](#)